IMPLEMENTASI DATA PREPARATION DATA PREPROCESSING PADA KNIME ANALYTICS PLATFORM UNTUK TUJUH JENIS TIPE DATA: INTERVAL RASIO, NOMINAL, ORDINAL, TEKS DERET WAKTU, DAN GAMBAR

LAPORAN PEKAN 1

Raditya Mulya Akbar
425 23 011

PROGRAM STUDI S1 TERAPAN TEKNIK KOMPUTER DAN JARINGAN
JURUSAN TEKNIK INFORMATIKA DAN KOMPUTER
POLITEKNIK NEGERI UJUNG PANDANG
MAKASSAR
2026

DAFTAR ISI

DAFTAR ISI ii
BAB I. PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Rumusan Masalah 1
1.3 Tujuan Penulisan 1
1.4 Manfaat Penulisan 2
BAB II. TINJAUAN PUSTAKA 3
2.1 Data Preparation dan Data Preprocessing 3
2.2 Klasifikasi Skala Data 3
2.3 KNIME Analytics Platform 3
2.4 Analisis Deskriptif 3
BAB III. METODOLOGI 5
3.1 Pendekatan 5
3.2 Sumber Dataset 5
BAB IV PEMBAHASAN 6
4.1 Data Interval Suhu Kota Jakarta 6
4.2 Data Rasio Usia dan Gaji Karyawan 7
4.3 Data Nominal Data Nasabah Bank 8
4.4 Data Ordinal Jenjang Pendidikan 9
4.5 Data Teks Ulasan Twitter 10
4.6 Data Deret Waktu Suhu Harian Delhi 11
4.7 Data Gambar Citra Pemandangan Alam 13
BAB V PENUTUP 14
5.1 Kesimpulan 14
5.2 Saran 14

BAB I. PENDAHULUAN

1.1 Latar Belakang

Kualitas data mentah menjadi faktor penentu utama validitas hasil analisis data maupun pembelajaran mesin. Data yang diperoleh dari lapangan umumnya belum siap digunakan secara langsung karena mengandung berbagai permasalahan, seperti nilai hilang (missing value), duplikasi, nilai pencilan (outlier), skala atribut yang tidak seragam, maupun format yang tidak konsisten. Permasalahan ini bahkan dapat berbeda karakteristiknya tergantung pada jenis skala pengukuran data yang dihadapi interval, rasio, nominal, ordinal, teks, deret waktu, maupun gambar.

KNIME (*Konstanz Information Miner*) merupakan platform analitik data berbasis visual programming yang bersifat *open-source*, memungkinkan pengguna melakukan proses ETL (*Extract, Transform, Load*), pembersihan data, dan transformasi tanpa harus menuliskan kode pemrograman secara ekstensif. Laporan ini disusun berdasarkan praktik langsung membangun pipeline data preparation dan data preprocessing di *KNIME* untuk tujuh tipe data yang berbeda, dengan tujuan menunjukkan penerapan nyata sekaligus mendokumentasikan tantangan teknis yang dihadapi selama proses tersebut.

1.2 Rumusan Masalah

1. Bagaimana tahapan *data preparation* dan *data preprocessing* diterapkan pada tujuh tipe *data* yang berbeda menggunakan *KNIME Analytics Platform*?
2. Node dan konfigurasi apa saja yang relevan digunakan untuk masing-masing tipe data, beserta justifikasi pemilihannya?
3. Apa saja tantangan teknis yang ditemui selama praktik, dan bagaimana solusinya?
4. Bagaimana hasil analisis deskriptif yang dihasilkan dari tiap pipeline yang telah dibangun?

1.3 Tujuan Penulisan

1. Mendokumentasikan *pipeline data preparation* dan *data preprocessing* untuk data interval, rasio, nominal, ordinal, teks, deret waktu, dan gambar.
2. Menjelaskan konfigurasi serta justifikasi teknis setiap node yang digunakan.
3. Mengevaluasi hasil serta keterbatasan yang ditemukan selama praktik.
4. Menyajikan hasil analisis deskriptif sebagai luaran akhir tiap pipeline.

1.4 Manfaat Penulisan

Laporan ini diharapkan menjadi referensi praktis bagi mahasiswa maupun praktisi yang ingin mempelajari penerapan data preparation dan preprocessing lintas tipe data menggunakan KNIME, termasuk memahami keterbatasan nyata yang mungkin dihadapi di lapangan dan bagaimana solusinya.

BAB II. TINJAUAN PUSTAKA

2.1 Data Preparation dan Data Preprocessing

Data preparation mencakup proses pengumpulan, penggabungan, dan penataan data dari berbagai sumber sebelum dianalisis lebih lanjut. Data preprocessing lebih berfokus pada perbaikan kualitas data, mencakup pembersihan, transformasi, reduksi, dan integrasi data agar sesuai kebutuhan algoritme analisis. Meskipun secara definisi preprocessing merupakan bagian dari preparation, dalam praktiknya kedua istilah sering digunakan secara tumpang tindih.

2.2 Klasifikasi Skala Data

Data numerik terbagi menjadi interval (memiliki jarak yang jelas namun tanpa titik nol mutlak, misalnya suhu Celcius dan tahun) dan rasio (memiliki titik nol mutlak, misalnya berat badan dan pendapatan). Data kategorikal terbagi menjadi nominal (kategori tanpa urutan, misalnya jenis kelamin) dan ordinal (kategori dengan urutan/tingkatan, misalnya jenjang pendidikan). Selain itu, terdapat tipe data khusus yang memerlukan perlakuan preprocessing tersendiri, yaitu data teks, data deret waktu (time series), dan data gambar.

2.3 KNIME Analytics Platform

KNIME adalah platform analitik data berbasis visual programming yang dikembangkan sejak tahun 2006, bersifat open-source di bawah lisensi GNU General Public License. KNIME mengintegrasikan komponen pembelajaran mesin dan penambangan data melalui konsep modular data pipelining, dengan dukungan ekstensi tambahan seperti KNIME Text Processing dan KNIME Image Processing untuk menangani tipe data khusus.

2.4 Analisis Deskriptif

Analisis deskriptif adalah metode statistik untuk meringkas, menggambarkan, dan menyajikan sekumpulan data agar mudah dipahami tanpa membuat kesimpulan yang berlaku umum untuk populasi. Ukuran yang umum digunakan meliputi ukuran pemusatan (mean, median, modus), ukuran penyebaran

(min, max, standar deviasi), dan penyajian visual (tabel distribusi frekuensi, histogram, bar chart, box plot, line chart). Ukuran pemusatan yang valid digunakan bergantung pada skala data: modus untuk nominal, median/modus untuk ordinal, serta mean/median untuk interval dan rasio.

BAB III. METODOLOGI

3.1 Pendekatan

Laporan ini disusun melalui praktik langsung (hands-on) membangun dan mengeksekusi workflow KNIME untuk tujuh tipe data, masing-masing menggunakan dataset publik yang representatif terhadap karakteristik tipe data tersebut.

3.2 Sumber Dataset

Tabel dibawah ini merangkum dataset yang digunakan untuk tiap tipe data beserta sumbernya.

Tipe Data	Dataset & Sumber
Interval	Daily Minimum/Global Land Temperatures by City (Berkeley Earth) (www.kaggle.com/datasets/berkeleyearth/climate-change-earth-surface-temperature-data)
Rasio	Salary Data based on Experience, Age, Gender, Job Title and Education Level (www.kaggle.com/datasets/mohithsairamreddy/salary-data)
Nominal & Ordinal	UCI Bank Marketing Dataset (bank-full.csv) (www.kaggle.com/datasets/adityamhaske/bank-marketing-dataset)
Teks	Twitter Tweets Sentiment Dataset (www.kaggle.com/datasets/yasserh/twitter-tweets-sentiment-dataset)
Deret Waktu	Daily Climate Time Series Data (Delhi) (www.kaggle.com/datasets/sumanthvrao/daily-climate-time-series-data)
Gambar	Intel Image Classification (www.kaggle.com/datasets/puneet6060/intel-image-classification)

BAB IV PEMBAHASAN

4.1 Data Interval Suhu Kota Jakarta

Dataset suhu global (Berkeley Earth) difilter khusus untuk Kota Jakarta guna menghindari pencampuran statistik antar-iklim berbeda.

Node	Konfigurasi Kunci	Fungsi & Alasan
CSV Reader	Autodetect format; decimal separator titik; kolom disaring: dt, City, Country, AverageTemperature	Impor GlobalLandTemperaturesByMajorCity.csv; menyaring kolom relevan sejak awal
String to Date&Time	Kolom dt; format yyyy-MM-dd; tipe Date; Replace	Mengonversi tanggal String menjadi Date agar dapat diurutkan & diekstrak kronologis
Date&Time Part Extractor	Field: Year; kolom baru Year (Integer)	Mengekstrak variabel tahun sesuai definisi data interval (suhu, tahun)
Row Filter	City = "Jakarta"; operator sama dengan	Membatasi analisis pada satu kota agar statistik tidak tercampur antar-iklim
Missing Value	Treatment by Column; AverageTemperature -> Mean	Data kontinu; Mean valid & menghasilkan PMML standar
Numeric Outliers	k=1.5; Full data estimate; Replace -> Closest permitted value	Winsorizing nilai ekstrem tanpa mengurangi jumlah baris
Statistics	Calculate median = ya; kolom AverageTemperature & Year; histogram PNG	Menghasilkan ukuran pemusatan & penyebaran

Hasil node Statistics pada kolom AverageTemperature (n = 2265, rentang tahun 1825-2013) ditampilkan pada tabel dibawah ini.

Metrik	Nilai
Min / Max	25,13 / 27,89 °C
Mean	26,51 °C

Median	26,51 °C
Std. Deviation	0,577
Skewness	0,088 (mendekati simetris)
Kurtosis	0,0057 (mendekati normal)
No. Missing	0

Nilai Mean dan Median yang hampir identik mengonfirmasi distribusi suhu yang simetris, menjustifikasi keputusan menggunakan Mean pada tahap penanganan missing value. Sesuai karakteristik skala interval, suhu Celcius tidak memiliki titik nol mutlak, sehingga interpretasi perbandingan dilakukan dalam bentuk selisih derajat, bukan rasio/kelipatan.

4.2 Data Rasio Usia dan Gaji Karyawan

Dataset Salary Data digunakan untuk merepresentasikan data rasio, dengan variabel Age dan Salary sebagai fokus analisis.

Node	**Konfigurasi Kunci**	**Fungsi & Alasan**
CSV Reader	Kolom disaring: Age, Gender, Salary	Impor Salary Data; fokus tiga variabel rasio inti
Missing Value	Treatment by Column; Salary -> Median	Gaji cenderung skewed; Median tahan nilai ekstrem
Numeric Outliers	k=1.5; grouping per Gender; Replace -> Closest permitted value	Gaji wajar berbeda antar kelompok; deteksi per grup
Math Formula (deprecated)	Expression log10($Salary$+1); Append -> Salary_Log	Transformasi logaritmik menghaluskan skewness
Statistics	Calculate median = ya; kolom Age, Salary, Salary_Log	Membandingkan Mean vs Median data asli & hasil transformasi
Box Plot	Dimension: Salary & Salary_Log; Condition: Gender	Visualisasi outlier & sebaran per kelompok gender

Hasil node Statistics (n = 6704) ditampilkan pada tabel dibawah ini.

Metrik	**Age**	**Salary**	**Salary_Log**

Min / Max	21 / 62	500 / 240.000	2,70 / 5,38
Mean	33,62	114.813,16	5,00
Median	32,00	115.000,00	5,06
Std. Deviation	7,61	52.447,41	0,241
Skewness	0,906	0,070	-0,936
No. Missing	2	0	0

Dua temuan metodologis penting teridentifikasi. Pertama, kolom Age masih memiliki dua nilai hilang yang belum tertangani karena konfigurasi Missing Value hanya diarahkan pada kolom Salary; hal ini dicatat sebagai keterbatasan pipeline. Kedua, skewness Salary pasca penanganan outlier (0,070) menunjukkan distribusi yang telah mendekati simetris, sedangkan Salary_Log justru menunjukkan skewness lebih besar berlawanan arah (-0,936). Temuan ini mengindikasikan bahwa transformasi logaritmik yang diterapkan setelah penanganan outlier menyebabkan overkoreksi, sehingga secara metodologis transformasi log idealnya diterapkan sebelum, bukan sesudah, penanganan outlier.

4.3 Data Nominal Data Nasabah Bank

Dataset UCI Bank Marketing (bank-full.csv, n = 45.211) digunakan untuk merepresentasikan empat variabel nominal: job, marital, housing, dan contact.

Node	**Konfigurasi Kunci**	**Fungsi & Alasan**
CSV Reader	Delimiter titik koma; kolom: job, marital, housing, contact	Impor bank-full.csv (UCI Bank Marketing)
String Manipulation (x4)	strip(...); replace(".","") khusus job; Replace	Standardisasi teks: hapus spasi & tanda titik
Missing Value	String -> Most Frequent Value	Verifikasi; "unknown" dianggap kategori sah
GroupBy (x4, paralel)	Group: job/marital/housing/contact; Aggregation Count	Menghitung frekuensi tiap kategori

Bar Chart (x4, paralel)	Category = kolom nominal; Value = Count	Visualisasi proporsi tiap kategori

Hasil GroupBy (frekuensi kategori) ditampilkan pada tabel dibawah ini.

Variabel	Modus (Kategori Tersering)	Frekuensi	Proporsi
job	blue-collar	9.732	21,5%
marital	married	27.214	60,2%
housing	yes	25.130	55,6%
contact	cellular	29.285	64,8%

Karena seluruh variabel bersifat nominal (tanpa urutan), satu-satunya ukuran pemusatan yang sah adalah modus, sebagaimana ditampilkan pada tabel di atas. Temuan menarik pada variabel contact: kategori unknown (28,8%) jauh lebih besar dari telephone (6,4%), mengindikasikan banyak metode kontak yang tidak tercatat jelas dalam data historis.

4.4 Data Ordinal Jenjang Pendidikan

Variabel education pada dataset yang sama digunakan untuk merepresentasikan data ordinal, dengan urutan unknown < primary < secondary < tertiary.

Node	Konfigurasi Kunci	Fungsi & Alasan
CSV Reader	Kolom: education, age (pendukung Count)	Impor bank-full.csv; isolasi variabel ordinal
Rule Engine	primary=1, secondary=2, tertiary=3, unknown=0; Append	Kode urutan eksplisit sesuai jenjang, bukan alfabetis
Missing Value	String -> Most Frequent Value; Integer -> Median	Strategi berbeda untuk representasi teks vs angka ordinal
GroupBy	Group: education & Education_Rank; Count(age)	Frekuensi tiap jenjang + kode urutan
Sorter	Column Education_Rank; Ascending	Urutan tampil sesuai jenjang, bukan alfabetis

education	Education_Rank	Frekuensi
unknown	0	1.857
primary	1	6.851
secondary	2	23.202
tertiary	3	13.301

Penggunaan node Rule Engine untuk memberi kode urutan eksplisit (bukan Category To Number yang bergantung pada urutan domain/alfabetis) terbukti krusial, karena kategori unknown harus ditempatkan pada posisi rank terendah (0), bukan pada posisi terakhir secara alfabetis. Jenjang secondary mendominasi dengan 23.202 nasabah (51,3%).

4.5 Data Teks Ulasan Twitter

Dataset Twitter Tweets Sentiment digunakan untuk mendemonstrasikan pipeline preprocessing teks lengkap.

Node	Konfigurasi Kunci	Fungsi & Alasan
CSV Reader	Kolom: text, sentiment; Encoding UTF-8	Impor Twitter Tweets Sentiment Dataset
Strings to Document	Full text: text; Title: Empty strings; Category: sentiment	Konversi teks mentah menjadi objek Document
Case Converter	Lower case; Replace	Menyeragamkan huruf
Punctuation Erasure	Replace	Menghapus tanda baca & simbol
Number Filter	Filter representing numbers = ya; containing numbers = tidak	Hapus token angka murni, pertahankan istilah alfanumerik
Stop Word Filter	Built-in list English; Replace	Membuang kata umum tak bermakna
Snowball Stemmer	Stemmer English; Replace	Memotong imbuhan ke bentuk dasar

Bag Of Words Creator	sertakan kolom Document	Memecah dokumen menjadi baris term
TF	Relative frequency = ya	Frekuensi relatif term ternormalisasi panjang dokumen

Contoh hasil akhir node TF (Term Frequency relatif) pada tingkat per-dokumen ditampilkan pada Tabel berikut sebagai ilustrasi keluaran.

Term	**TF (Relatif)**
miss	0,20
san	0,20
diego	0,20
boss	0,50
bulli	0,50
interview	0,50
leav	0,50

Satu temuan teknis penting: kolom identitas dokumen (Title) pada node Strings to Document semula diisi RowID, yang menyebabkan token "row0", "row1", dst. secara keliru ikut terhitung sebagai term oleh node Bag Of Words Creator. Masalah ini diperbaiki dengan mengubah Title menjadi Empty Strings, dengan konsekuensi hilangnya keterlacakan dokumen asal pada tabel akhir sebuah trade-off yang secara sadar diterima mengingat fokus laporan pada validitas nilai frekuensi term, bukan penelusuran per-dokumen. Kata dasar hasil Snowball Stemmer (mis. "bulli", "interview", "leav") menunjukkan sifat algoritmik stemming berbasis pemotongan akhiran, bukan kamus makna, sehingga hasilnya tidak selalu berupa kata baku.

4.6 Data Deret Waktu Suhu Harian Delhi

Dataset Daily Climate Time Series Data (Delhi, n = 1462) digunakan untuk pipeline deret waktu.

Node	Konfigurasi Kunci	Fungsi & Alasan
CSV Reader	Kolom: date, meantemp	Impor Daily Climate Time Series Data (Delhi)
String to Date&Time	Format yyyy-MM-dd; Replace	Konversi tanggal harian ke tipe Date
Sorter	Column date; Ascending	Menjamin urutan kronologis
Missing Value	meantemp -> Linear Interpolation	Mempertahankan tren lokal, berbeda dari Mean global
Date&Time Part Extractor	Field: Month (Number)	Variabel musiman untuk grouping outlier
Numeric Outliers	Group: Month; Replace -> Closest permitted value	Deteksi outlier kontekstual per bulan
Date&Time to Legacy Date&Time	Kolom date; Replace	Kompatibilitas dengan node Line Chart (JFreeChart)
Line Chart (JFreeChart)	X: date; Y: meantemp	Visualisasi tren & pola musiman

Line Chart hasil akhir pipeline menampilkan tren suhu harian sepanjang 2013-2017, dengan pola musiman berulang (gelombang naik-turun tiap tahun) yang menjadi ciri khas visualisasi data deret waktu, berbeda dari tipe data lain yang tidak memiliki struktur temporal berurutan. Dua keputusan metodologis penting pada pipeline ini: (1) penggunaan Linear Interpolation, bukan Mean global, untuk menangani nilai hilang agar pola tren lokal tidak rusak, dan (2) deteksi outlier dikelompokkan per bulan (bukan secara global) agar variasi suhu musiman alami (panas ekstrem di pertengahan tahun, sejuk di awal/akhir tahun) tidak keliru ditandai sebagai anomali.

Kendala teknis yang ditemui dan solusinya: node Line Chart (JFreeChart) merupakan node lawas yang hanya mengenali tipe Date and Time (legacy), sedangkan hasil konversi String to Date&Time menghasilkan tipe Local Date (modern). Kendala ini diselesaikan dengan menyisipkan node konversi Date&Time to Legacy Date&Time sebelum Line Chart.

4.7 Data Gambar Citra Pemandangan Alam

Dataset Intel Image Classification (subset 15-20 gambar) digunakan untuk pipeline data gambar.

Node	Konfigurasi Kunci	Fungsi & Alasan
Image Reader	Pixel type Automatic; Array Image Factory	Impor sampel gambar Intel Image Classification
Image Resizer	Absolute Image Size 150x150; Linear Interpolation	Menyamakan dimensi seluruh gambar
Projector	Projection Mean; Direction Channel	Meratakan RGB menjadi grayscale
Image Normalizer	Manual; target min=0 max=1; Dimension X,Y	Menstandardisasi rentang nilai piksel ke 0-1

Pipeline ini menghadapi dua keterbatasan teknis yang perlu diungkapkan secara transparan. Pertama, node statistik/fitur pada ekstensi KNIME Image Processing dirancang khusus untuk gambar yang telah melalui proses segmentasi (memerlukan kolom Labeling sebagai region of interest), bukan untuk ekstraksi statistik piksel pada gambar utuh secara langsung, sehingga analisis histogram intensitas piksel secara kuantitatif tidak dapat diselesaikan dalam cakupan praktik ini. Kedua, representasi visual gambar pascanormalisasi tampak sangat gelap karena banyak image viewer mengasumsikan rentang tampilan 0-255, sementara data telah dinormalisasi ke rentang 0-1 sesuai konfigurasi Manual pada node Image Normalizer nilai piksel yang mendasarinya tetap valid secara matematis meskipun tampilan visualnya menyesatkan.

Sebagai gantinya, validasi keberhasilan pipeline preprocessing gambar dilakukan secara visual melalui perbandingan pratinjau (interactive view) gambar sebelum dan sesudah tahap resizing, konversi grayscale, dan normalisasi.

BAB V PENUTUP

5.1 Kesimpulan

1. KNIME Analytics Platform terbukti mampu menangani ketujuh tipe data (interval, rasio, nominal, ordinal, teks, deret waktu, dan gambar) melalui pendekatan visual programming, meskipun tiap tipe data memerlukan node dan strategi preprocessing yang berbeda sesuai karakteristik skalanya.
2. Pemilihan metode penanganan missing value dan outlier harus disesuaikan dengan konteks data Mean untuk data simetris (interval), Median untuk data skewed (rasio), Most Frequent Value untuk kategorikal (nominal/ordinal), dan Linear Interpolation untuk deret waktu agar pola temporal tidak rusak.
3. Ditemukan sejumlah tantangan teknis nyata selama praktik, meliputi node deprecated (String to Date&Time, Math Formula, String Manipulation), inkompatibilitas tipe data antar-generasi node (Line Chart legacy vs Local Date modern), serta keterbatasan node komunitas KNIME Image Processing dalam ekstraksi statistik piksel tanpa segmentasi.
4. Urutan penerapan langkah preprocessing terbukti berpengaruh terhadap validitas hasil, sebagaimana ditunjukkan oleh temuan pada data rasio di mana transformasi logaritmik yang diterapkan setelah penanganan outlier menghasilkan skewness yang lebih besar, bukan lebih kecil.

5.2 Saran

Untuk pengembangan lebih lanjut, disarankan untuk: (1) melengkapi penanganan missing value pada seluruh kolom relevan (termasuk Age pada data rasio) secara lebih menyeluruh; (2) menguji ulang urutan transformasi log dan penanganan outlier pada data rasio untuk memastikan hasil yang tidak overkoreksi; (3) mengeksplorasi node statistik berbasis segmentasi pada KNIME Image Processing untuk melengkapi analisis kuantitatif data gambar, serta (4) melengkapi analisis deskriptif data teks dengan visualisasi Tag Cloud dan agregasi Term Frequency lintas dokumen sebagai pengembangan lanjutan.