PENANGANAN *UNBALANCED DATASET* MELALUI PENERAPAN ALGORITMA *EQUAL SIZE SAMPLING* DAN *SMOTE* PADA *KNIME ANALYTICS PLATFORM*: STUDI KASUS DATA PEMASARAN *BANK*

LAPORAN PEKAN 3

Raditya Mulya Akbar
425 23 011

PROGRAM STUDI S1 TERAPAN TEKNIK KOMPUTER DAN JARINGAN
JURUSAN TEKNIK INFORMATIKA DAN KOMPUTER
POLITEKNIK NEGERI UJUNG PANDANG
MAKASSAR
2026

DAFTAR ISI

DAFTAR ISI ii

DAFTAR TABEL iv

BAB I. PENDAHULUAN 1

1.1 Latar Belakang 1

1.2 Rumusan Masalah 1

1.3 Tujuan Penulisan 1

1.4 Manfaat Penulisan 2

BAB II. TINJAUAN PUSTAKA 3

2.1 Unbalanced Dataset 3

2.2 Teknik Penanganan Unbalanced Dataset 3

2.3 Prasyarat Metodologis SMOTE 3

2.4 Metrik Evaluasi untuk Data Tidak Seimbang 4

BAB III. METODOLOGI 5

3.1 Dataset dan Distribusi Baseline 5

3.2 Kerangka Eksperimen 5

BAB IV. PEMBAHASAN 6

4.1 Data Preparation dan Partitioning 6

4.2 Penerapan Teknik Balancing pada Data Latih 6

4.3 Pemodelan dan Evaluasi 7

4.3.1 Confusion Matrix per Skenario 7

4.3.2 Perbandingan Metrik Evaluasi 7

4.4 Analisis Kritis 8

4.4.1 Equal Size Sampling: Trade-off Recall vs Precision 8

4.4.2 SMOTE: Keterbatasan Metodologis pada Encoding Kategorikal 8

BAB V. PENUTUP 10

5.1 Kesimpulan 10

5.2 Saran 10

DAFTAR PUSTAKA..... 11

DAFTAR TABEL

Tabel 3.1 Distribusi Kelas Target Sebelum Balancing (Baseline) 5
Tabel 4.1 Pipeline Data Preparation dan Partitioning 6
Tabel 4.2 Pipeline Penerapan Teknik Balancing..... 6
Tabel 4.3 Pipeline Pemodelan dan Evaluasi..... 7
Tabel 4.4 Confusion Matrix Ketiga Skenario (Kelas Positif = yes)..... 7
Tabel 4.5 Perbandingan Metrik Evaluasi Ketiga Skenario..... 8

BAB I. PENDAHULUAN

1.1 Latar Belakang

Dalam klasifikasi data, ketidakseimbangan kelas (*class imbalance*) terjadi ketika satu kategori target memiliki jumlah anggota jauh lebih banyak dibandingkan kategori lainnya. Kondisi ini menimbulkan tantangan tersendiri bagi algoritma pembelajaran mesin, karena model cenderung bias memaksimalkan akurasi keseluruhan dengan cara mengabaikan kelas minoritas padahal kelas minoritas tersebut, dalam banyak konteks bisnis, justru merupakan target analisis yang paling bernilai (misalnya nasabah yang berpotensi churn, transaksi yang berpotensi fraud, atau dalam kasus laporan ini, nasabah yang berpotensi berlangganan produk deposito).

Laporan ini menggunakan *Bank Marketing Dataset* dari *UCI Machine Learning Repository*, sebuah dataset yang telah banyak digunakan dalam literatur akademik sebagai studi kasus klasik ketidakseimbangan kelas, dengan proporsi kelas target sebesar 88,3% (tidak berlangganan) berbanding 11,7% (berlangganan). Dua pendekatan balancing yang tersedia pada *KNIME Analytics Platform* diterapkan dan dibandingkan secara empiris melalui pengujian model klasifikasi *Decision Tree*.

1.2 Rumusan Masalah

1. Bagaimana karakteristik distribusi kelas pada *dataset* pemasaran bank sebelum dilakukan penanganan?
2. Bagaimana penerapan teknik *Equal Size Sampling* (*undersampling*) dan *SMOTE* (*oversampling* sintetis) pada KNIME Analytics Platform?
3. Bagaimana dampak kedua teknik balancing tersebut terhadap performa model klasifikasi *Decision Tree*, dibandingkan dengan kondisi tanpa *balancing*?
4. Apa keterbatasan metodologis yang perlu diperhatikan dalam penerapan teknik balancing tersebut?

1.3 Tujuan Penulisan

1. Mendokumentasikan pipeline penanganan *unbalanced dataset* menggunakan *KNIME Analytics Platform*.
2. Membandingkan dampak teknik undersampling dan oversampling sintetis terhadap metrik evaluasi model klasifikasi.
3. Mengidentifikasi *trade-off* dan keterbatasan metodologis dari masing-masing teknik *balancing*.

1.4 Manfaat Penulisan

Laporan ini diharapkan menjadi referensi praktis bagi mahasiswa maupun praktisi data yang ingin memahami penerapan teknik *balancing dataset* menggunakan *KNIME*, sekaligus memahami bahwa penerapan teknik yang lebih kompleks (seperti *SMOTE*) tidak selalu menjamin hasil yang lebih baik apabila prasyarat metodologisnya tidak terpenuhi.

BAB II. TINJAUAN PUSTAKA

2.1 Unbalanced Dataset

Unbalanced dataset (*dataset* tidak seimbang) merujuk pada kondisi distribusi kelas target yang timpang, di mana satu atau beberapa kelas (kelas mayoritas) memiliki jumlah observasi yang jauh lebih banyak dibandingkan kelas lain (kelas minoritas). Kondisi ini dapat menyebabkan model klasifikasi menghasilkan akurasi keseluruhan yang tampak tinggi, namun sebenarnya gagal mengenali pola pada kelas minoritas fenomena yang dikenal sebagai *accuracy paradox*.

2.2 Teknik Penanganan Unbalanced Dataset

Terdapat dua pendekatan utama dalam menangani ketidakseimbangan kelas pada tingkat data (data-level approach):

1. Undersampling: mengurangi jumlah observasi pada kelas mayoritas hingga proporsinya setara dengan kelas minoritas. Pada KNIME, teknik ini diimplementasikan melalui node Equal Size Sampling, yang membuang baris secara acak dari kelas mayoritas.
2. Oversampling: menambah jumlah observasi pada kelas minoritas, baik melalui duplikasi sederhana (random oversampling) maupun melalui pembangkitan data sintetis. SMOTE (Synthetic Minority Over-sampling Technique), diperkenalkan oleh Chawla et al. (2002), membangkitkan data sintetis dengan cara interpolasi antara satu observasi kelas minoritas dengan salah satu tetangga terdekatnya (k-nearest neighbor).

2.3 Prasyarat Metodologis SMOTE

Karena SMOTE bekerja berdasarkan interpolasi jarak matematis antar-observasi, algoritma ini mensyaratkan seluruh atribut prediktor dalam bentuk numerik. Konsekuensinya, atribut kategorikal perlu diubah (encoding) menjadi representasi numerik sebelum SMOTE diterapkan. Encoding tanpa mempertimbangkan makna ordinal (misalnya melalui pemetaan kategori ke angka secara arbitrer) berisiko menghasilkan observasi sintetis yang tidak bermakna

secara semantik, karena nilai interpolasi di antara dua kategori nominal tidak merepresentasikan kategori nyata mana pun.

2.4 Metrik Evaluasi untuk Data Tidak Seimbang

Pada kasus unbalanced dataset, metrik Accuracy semata tidak memadai untuk menilai performa model, karena model yang secara konsisten memprediksi kelas mayoritas dapat memperoleh Accuracy tinggi tanpa benar-benar mengenali pola kelas minoritas. Metrik yang lebih relevan meliputi Recall (proporsi kelas minoritas yang berhasil terdeteksi), Precision (proporsi prediksi positif yang benar-benar tepat), F-measure (harmonic mean Precision dan Recall), serta Cohen's Kappa (mengukur kesesuaian prediksi dengan memperhitungkan kemungkinan kecocokan acak).

BAB III. METODOLOGI

3.1 Dataset dan Distribusi Baseline

Dataset yang digunakan adalah bank-full.csv dari UCI Bank Marketing Dataset, berisi 45.211 observasi dengan variabel target y (status berlangganan deposito berjangka: yes/no). Delapan atribut digunakan dalam praktik ini: age, job, marital, education, balance, housing, loan, dan y. Atribut duration sengaja dikecualikan mengikuti rekomendasi dokumentasi resmi dataset, karena durasi panggilan hanya diketahui setelah panggilan selesai dilakukan, sehingga penyertaannya akan menyebabkan kebocoran data (data leakage) pada skenario prediksi realistis.

Distribusi awal variabel target (baseline, sebelum balancing apa pun) ditampilkan pada Tabel 3.1.

Kategori y	Jumlah	Proporsi
no (tidak berlangganan)	39.922	88,30%
yes (berlangganan)	5.289	11,70%
Total	45.211	100%

Tabel 3.1 Distribusi Kelas Target Sebelum Balancing (Baseline)

Rasio ketidakseimbangan sekitar 1:7,55 ini tergolong severely imbalanced dan telah menjadi studi kasus dalam berbagai penelitian akademik terkait klasifikasi data tidak seimbang.

3.2 Kerangka Eksperimen

Untuk memastikan evaluasi yang valid, dataset terlebih dahulu dibagi menjadi data latih (training, 70%) dan data uji (testing, 30%) menggunakan stratified sampling, SEBELUM proses balancing apa pun diterapkan. Teknik balancing (Equal Size Sampling dan SMOTE) hanya diterapkan pada data latih, sementara data uji tetap mempertahankan distribusi aslinya (88,3% : 11,7%) agar merepresentasikan kondisi data dunia nyata secara jujur. Tiga skenario dibangun dan dibandingkan: (1) tanpa balancing, (2) dengan Equal Size Sampling, dan (3) dengan SMOTE, masing-masing dilatih menggunakan algoritma Decision Tree dan diuji pada satu data uji yang sama.

BAB IV. PEMBAHASAN

4.1 Data Preparation dan Partitioning

Node	Konfigurasi Kunci	Fungsi & Alasan
CSV Reader	Delimiter titik koma; kolom disaring: age, job, marital, education, balance, housing, loan, y	Impor bank-full.csv; kolom duration sengaja dibuang karena berisiko data leakage (durasi hanya diketahui setelah panggilan terjadi)
Table Partitioner	Relative size 70%; Sampling strategy: Stratified; Group column: y; seed = 42	Membagi data menjadi training (70%) dan testing (30%) SEBELUM balancing, dengan proporsi kelas y tetap terjaga di kedua partisi agar evaluasi model tetap representatif terhadap data dunia nyata

Tabel 4.1 Pipeline Data Preparation dan Partitioning

Hasil partitioning menghasilkan 31.647 baris data latih dan 13.564 baris data uji, dengan proporsi kelas y yang tetap terjaga sesuai baseline pada kedua partisi berkat penerapan stratified sampling.

4.2 Penerapan Teknik Balancing pada Data Latih

Node	Konfigurasi Kunci	Fungsi & Alasan
Equal Size Sampling	Nominal column: y; Use exact sampling; Enable static seed = ya, seed = 42	Undersampling: memangkas kelas mayoritas (no) hingga jumlahnya sama dengan kelas minoritas (yes) pada training set
Category to Number	Columns: job, marital, education, housing, loan; Replace (bukan Append)	Meng-encode kolom kategorikal menjadi numerik sebagai prasyarat teknis SMOTE, yang bekerja berbasis interpolasi jarak matematis
SMOTE	Class column: y; #Nearest neighbor = 5; Oversampling method: Minority classes; seed = 42	Oversampling: menambah kelas minoritas (yes) dengan data sintetis hasil interpolasi hingga menyamai jumlah kelas mayoritas pada training set

Tabel 4.2 Pipeline Penerapan Teknik Balancing

Equal Size Sampling diterapkan langsung pada data latih (tipe data campuran nominal dan numerik tidak menjadi kendala, karena teknik ini bekerja dengan membuang baris, bukan menghitung jarak). Sebaliknya, SMOTE mensyaratkan representasi numerik penuh, sehingga atribut kategorikal (job, marital, education, housing, loan) terlebih dahulu diubah menjadi numerik melalui Category to Number sebelum SMOTE dijalankan.

4.3 Pemodelan dan Evaluasi

Node	Konfigurasi Kunci	Fungsi & Alasan
Decision Tree Learner (x3, satu per skenario)	Class column: y; Quality measure: Gini index; Pruning: Reduced error pruning; Binary nominal splits = ya	Melatih model klasifikasi pada masing-masing training set (tanpa balancing, hasil Equal Size Sampling, hasil SMOTE)
Decision Tree Predictor (x3)	Model dari Learner sepasang; Data dari testing set (Port 2 Table Partitioner, TIDAK di-balancing); Append columns with normalized class distribution = ya	Menguji ketiga model pada satu testing set yang sama (representasi data dunia nyata, 88,3% : 11,7%) agar perbandingan adil
Scorer (x3)	First column: y; Second column: Prediction (y); Sorting: Lexical; Use name prefix = ya (NoBalance_/Undersample_/SMOTE_)	Menghasilkan confusion matrix dan metrik evaluasi (Accuracy, Precision, Recall, F-measure, Cohen's Kappa) untuk tiap skenario

Tabel 4.3 Pipeline Pemodelan dan Evaluasi

4.3.1 Confusion Matrix per Skenario

Skenario	True Positive	False Positive	True Negative	False Negative
Tanpa Balancing	420	955	11.022	1.167
Equal Size Sampling	987	600	7.091	4.886
SMOTE	257	1.330	10.223	1.754

Tabel 4.4 Confusion Matrix Ketiga Skenario (Kelas Positif = yes)

4.3.2 Perbandingan Metrik Evaluasi

Skenario	Recall (yes)	Precision (yes)	F-measure (yes)	Accuracy	Kappa
Tanpa Balancing	26,47%	30,55%	28,36%	84,36%	0,196
Equal Size Sampling	62,19%	16,81%	26,46%	59,55%	0,099
SMOTE	16,19%	12,78%	14,29%	77,26%	0,014

Tabel 4.5 Perbandingan Metrik Evaluasi Ketiga Skenario

4.4 Analisis Kritis

4.4.1 Equal Size Sampling: Trade-off Recall vs Precision

Undersampling melalui Equal Size Sampling berhasil meningkatkan Recall kelas yes secara signifikan, dari 26,47% (tanpa balancing) menjadi 62,19% -- lebih dari dua kali lipat. Namun peningkatan ini disertai penurunan tajam pada Precision (30,55% menjadi 16,81%) dan Accuracy keseluruhan (84,36% menjadi 59,55%). F-measure kelas yes bahkan sedikit menurun dibandingkan baseline (28,36% menjadi 26,46%), mengindikasikan bahwa peningkatan kemampuan mendeteksi kelas minoritas dicapai dengan mengorbankan jumlah false alarm yang jauh lebih banyak. Teknik ini relevan digunakan apabila konteks bisnis memprioritaskan Recall (menghindari nasabah potensial yang terlewat) di atas efisiensi biaya tindak lanjut terhadap false positive.

4.4.2 SMOTE: Keterbatasan Metodologis pada Encoding Kategorikal

Berlawanan dengan ekspektasi umum bahwa SMOTE sebagai teknik oversampling yang lebih canggih akan menghasilkan performa lebih baik, hasil praktik ini menunjukkan performa SMOTE yang lebih rendah dibandingkan baseline pada seluruh metrik kelas yes (Recall 16,19%, Precision 12,78%, F-measure 14,29%, Cohen's Kappa hanya 0,014 yang mengindikasikan kesesuaian prediksi mendekati acak). Analisis kritis mengindikasikan penyebab paling mungkin adalah proses encoding atribut kategorikal (job, marital, education, housing, loan) melalui node Category to Number sebelum SMOTE diterapkan. Encoding tersebut memetakan kategori nominal ke angka integer secara arbitrer tanpa makna ordinal. Karena SMOTE membangkitkan observasi sintetis melalui

interpolasi linear antara dua titik data, nilai desimal hasil interpolasi pada atribut yang semula kategorikal tidak merepresentasikan kategori apa pun secara bermakna, sehingga menghasilkan observasi sintetis yang secara semantik tidak valid.

Temuan ini menggarisbawahi prinsip penting dalam praktik data science: penerapan teknik yang secara teoritis lebih sophisticated (SMOTE) tidak secara otomatis menghasilkan performa lebih baik apabila prasyarat metodologisnya (representasi data yang bermakna) tidak terpenuhi. Untuk penerapan SMOTE yang lebih valid pada data campuran (mixed-type), disarankan penggunaan varian khusus seperti SMOTE-NC (SMOTE for Nominal and Continuous), yang menangani atribut kategorikal dan numerik secara terpisah, alih-alih Category to Number yang bersifat generik.

BAB V. PENUTUP

5.1 Kesimpulan

1. Dataset pemasaran bank yang digunakan memiliki ketidakseimbangan kelas yang parah (88,3% : 11,7%), merepresentasikan tantangan umum dalam klasifikasi data dunia nyata.
2. Equal Size Sampling (undersampling) secara signifikan meningkatkan Recall kelas minoritas namun menurunkan Precision dan Accuracy secara tajam, menunjukkan trade-off yang perlu disesuaikan dengan prioritas konteks bisnis.
3. SMOTE, dalam implementasi praktik ini, justru menghasilkan performa yang lebih rendah dibandingkan kondisi tanpa balancing, yang diduga kuat disebabkan oleh proses encoding atribut kategorikal secara arbitrer sebelum interpolasi SMOTE dilakukan.
4. Metrik Accuracy semata tidak memadai untuk mengevaluasi model pada dataset tidak seimbang; Recall, Precision, F-measure, dan Cohen's Kappa untuk kelas minoritas memberikan gambaran yang jauh lebih informatif.

5.2 Saran

Untuk pengembangan lebih lanjut, disarankan: (1) menguji varian SMOTE yang mendukung atribut kategorikal secara native (SMOTE-NC) sebagai pembanding; (2) menguji teknik balancing berbasis algoritma (class weighting pada Learner) sebagai pendekatan alternatif yang tidak memerlukan modifikasi data; (3) menguji beberapa algoritma klasifikasi lain (Random Forest, Logistic Regression) untuk memastikan temuan tidak spesifik terhadap satu jenis algoritma; serta (4) melakukan hyperparameter tuning (jumlah nearest neighbor SMOTE, rasio undersampling) untuk mengeksplorasi kemungkinan hasil yang lebih optimal.

DAFTAR PUSTAKA

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321-357.

Moro, S., Cortez, P., & Rita, P. (2014). Bank Marketing Dataset. UCI Machine Learning Repository. archive.ics.uci.edu/dataset/222/bank+marketing

Mhaske, A. UCI Bank Marketing Dataset. Kaggle. www.kaggle.com/datasets/adityamhaske/bank-marketing-dataset

Data-Driven Decision-Making for Bank Target Marketing Using Supervised Learning Classifiers on Imbalanced Big Data. (2024). Computers, Materials & Continua (CMC), 81(1). www.techscience.com/cmc/v81n1/58336/html

KNIME AG. KNIME Community Hub -- dokumentasi resmi node: CSV Reader, Table Partitioner, Equal Size Sampling, Category to Number, SMOTE, Decision Tree Learner, Decision Tree Predictor, Scorer. hub.knime.com