EKSPLORASI FITUR ORANGE DATA MINING DAN PERBANDINGANNYA DENGAN KNIME

LAPORAN

Raditya Mulya Akbar

425 23 011

PROGRAM STUDI S1 TERAPAN TEKNIK KOMPUTER DAN JARINGAN

JURUSAN TEKNIK INFORMATIKA DAN KOMPUTER

POLITEKNIK NEGERI UJUNG PANDANG

MAKASSAR

2026

DAFTAR ISI

DAFTAR ISI i
BAB I PENDAHULUAN 1
1.1 Latar Belakang 1
1.2 Tujuan 1
1.3 Ruang Lingkup dan Batasan 1
BAB II LANDASAN TEORI 3
2.1 Orange Data Mining 3
2.2 KNIME 3
2.3 Klasifikasi dan Metrik Evaluasi 3
2.4 Data Tidak Seimbang 4
BAB III METODE PRAKTIKUM 5
3.1 Instalasi pada Windows 5
3.2 Antarmuka Orange 5
3.3 Kategori Widget 6
3.4 Add-on 7
3.5 Ciri Khas Orange 7
3.6 Dataset 7
3.7 Impor dan Eksplorasi Data 8
3.8 Perancangan Workflow Klasifikasi 9
BAB IV HASIL DAN PEMBAHASAN 11
4.1 Hasil Evaluasi Model 11
4.2 Pembahasan 11
4.3 Confusion Matrix 12
4.4 Waktu Proses 13

4.5 Penanganan Data Tidak Seimbang di Orange 13
BAB V PERBANDINGAN ORANGE DAN KNIME 15
5.1 Perbandingan Fitur dan Karakteristik 15
5.2 Perbandingan Hasil Eksperimen 15
5.3 Ringkasan Perbandingan 16
BAB VI KESIMPULAN DAN SARAN 17
6.1 Kesimpulan 17
6.2 Saran 17
DAFTAR PUSTAKA 18

BAB I PENDAHULUAN

1.1 Latar Belakang

Data mining adalah proses menemukan pola dan pengetahuan yang bermanfaat dari kumpulan data berukuran besar. Untuk mengerjakannya, tersedia berbagai perangkat lunak berbasis pemrograman visual, yaitu perangkat yang menyusun alur analisis dengan menghubungkan komponen-komponen pada sebuah kanvas tanpa harus menulis banyak kode. Dua di antaranya adalah KNIME dan Orange Data Mining.

Dalam program magang di Center for Applied ICT Research (CAIR), penulis ditugaskan mempelajari sejumlah perangkat bantu analisis data dan menyusun tutorial lengkap beserta dataset dan video pembelajarannya. Pada tahap sebelumnya penulis telah mengeksplorasi KNIME, mulai dari persiapan data, pengolahan berbagai tipe data, hingga penanganan dataset tidak seimbang. Pada tahap ini penulis mempelajari Orange Data Mining dengan dua sasaran, yaitu mengenal fitur-fiturnya dan membandingkannya dengan KNIME dari sisi data mining.

Laporan ini mendokumentasikan proses instalasi Orange, tinjauan fitur yang tersedia, implementasi klasifikasi pada dataset Bank Marketing, serta perbandingan Orange dengan KNIME.

1.2 Tujuan

1. Memasang dan mengenali antarmuka serta kategori widget pada Orange Data Mining.
2. Meninjau fitur-fitur utama Orange untuk keperluan data mining.
3. Mengimplementasikan alur klasifikasi pada dataset Bank Marketing menggunakan Orange dan mengevaluasi hasilnya.
4. Membandingkan karakteristik, fitur, dan hasil Orange dengan KNIME.

1.3 Ruang Lingkup dan Batasan

Laporan ini mencakup instalasi Orange pada sistem operasi Windows, tinjauan kategori widget dan add-on, serta eksperimen klasifikasi pada dataset bank-full.csv dengan tiga algoritma (Tree, Naive Bayes, dan Random Forest) yang

dievaluasi menggunakan cross validation. Beberapa hal berada di luar cakupan laporan ini:

1. Penanganan data tidak seimbang di Orange hanya ditinjau dari dokumentasi dan sumber pustaka, tidak diujicobakan.
2. Klasterisasi, asosiasi, regresi, serta pemakaian add-on belum dibahas dan akan dilaporkan pada tahap berikutnya.
3. Perbandingan dengan KNIME bersifat kualitatif, ditambah satu perbandingan hasil terbatas yang dijelaskan keterbatasannya pada bagian hasil.

BAB II LANDASAN TEORI

2.1 Orange Data Mining

Orange adalah perangkat lunak data mining berbasis komponen yang bersifat open source. Perangkat ini menyediakan teknik visualisasi data, eksplorasi, prapemrosesan, dan pemodelan yang dapat digunakan melalui antarmuka grafis, dan juga dapat dipakai sebagai modul pada bahasa pemrograman Python (Demšar dkk., 2013). Pada antarmuka grafis, pengguna menyusun alur kerja (workflow) dengan menyeret widget ke kanvas lalu menghubungkannya dengan garis. Setiap widget menjalankan satu fungsi tertentu, misalnya memuat data, memilih kolom, melatih model, atau menampilkan grafik.

2.2 KNIME

KNIME adalah platform analitik data visual yang menyusun alur kerja dari node. Setiap node melakukan satu operasi dan dijalankan (execute) secara terpisah sehingga hasil antarnode dapat diperiksa satu per satu. Pada eksplorasi sebelumnya, penulis menggunakan KNIME untuk persiapan data dan eksperimen balancing pada dataset Bank Marketing, sehingga hasilnya dapat dijadikan pembanding.

2.3 Klasifikasi dan Metrik Evaluasi

Klasifikasi adalah proses melatih model untuk memprediksi kelas dari suatu data berdasarkan atribut-atributnya. Kinerja model dinilai dari confusion matrix, yaitu tabel yang membandingkan kelas sebenarnya dengan kelas hasil prediksi. Untuk kelas positif (pada penelitian ini kelas yes), empat nilai yang digunakan adalah TP (positif terprediksi benar), TN (negatif terprediksi benar), FP (negatif terprediksi positif), dan FN (positif terprediksi negatif). Metrik yang dipakai pada laporan ini adalah sebagai berikut.

$$\textit{Classification Accuracy (CA)} = (TP + TN) / (TP + TN + FP + FN)$$

$$\textit{Precision} = TP / (TP + FP)$$

$$\textit{Recall} = TP / (TP + FN)$$

$$F1 = 2 \times \textit{Precision} \times \textit{Recall} / (\textit{Precision} + \textit{Recall})$$

AUC (Area Under the ROC Curve) mengukur kemampuan model membedakan kelas positif dan negatif pada berbagai ambang probabilitas, sedangkan MCC (Matthews Correlation Coefficient) merangkum seluruh isi confusion matrix menjadi satu angka yang lebih tahan terhadap ketidakseimbangan kelas. Evaluasi dilakukan dengan k-fold cross validation, yaitu data dibagi menjadi k bagian yang bergantian menjadi data uji. Opsi stratified menjaga proporsi kelas pada setiap bagian.

2.4 Data Tidak Seimbang

Dataset dikatakan tidak seimbang apabila jumlah data pada satu kelas jauh lebih banyak daripada kelas lainnya. Pada kondisi ini, akurasi dapat menyesatkan karena model yang selalu memprediksi kelas mayoritas pun akan tampak akurat. Oleh karena itu, evaluasi pada dataset tidak seimbang sebaiknya berfokus pada recall, precision, dan F1 untuk kelas minoritas.

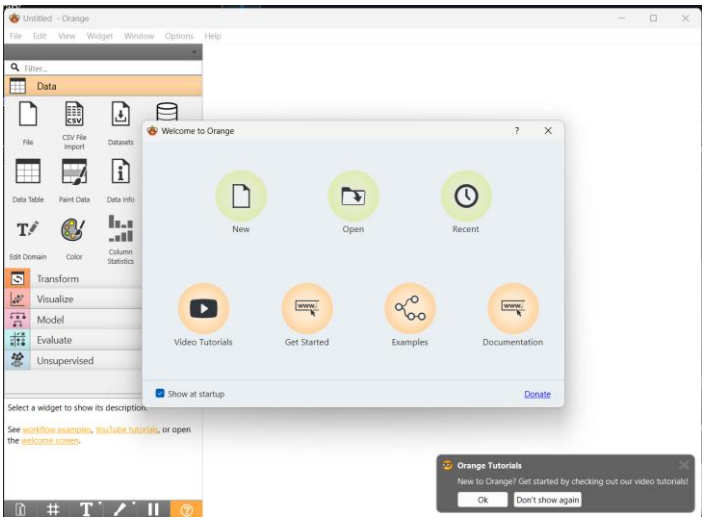
BAB III METODE PRAKTIKUM

3.1 Instalasi pada Windows

Orange dapat dipasang dengan beberapa cara, yaitu installer standalone dari situs resmi, melalui pip, atau melalui distribusi Anaconda. Penulis menggunakan installer standalone karena paling sederhana. Installer ini sudah menyertakan Python dan pustaka yang dibutuhkan sehingga tidak diperlukan instalasi tambahan. Langkah-langkahnya adalah sebagai berikut.

1. Mengunduh installer Orange untuk Windows dari halaman unduhan resmi (orangedatamining.com/download).
2. Menjalankan installer dan mengikuti wizard dengan pengaturan bawaan sampai proses instalasi selesai.
3. Membuka aplikasi Orange dari Start Menu. Pada pembukaan pertama muncul jendela Welcome to Orange.

Sebagai alternatif, Orange dapat dipasang pada lingkungan Python dengan perintah pip install orange3 dan dijalankan dengan perintah orange-canvas (Python Package Index, n.d.). Instalasi pada penelitian ini berhasil dan jendela Welcome tampil normal seperti pada Gambar dibawah ini.



3.2 Antarmuka Orange

Antarmuka Orange terdiri atas tiga bagian utama. Panel widget di sisi kiri memuat widget yang dikelompokkan per kategori dan dilengkapi kolom pencarian

(Filter). Kanvas di sisi kanan menjadi tempat menyusun workflow. Menu di bagian atas menyediakan pengaturan seperti File, Edit, View, Widget, Window, Options, dan Help. Jendela Welcome menyediakan akses cepat ke New (workflow baru), Open, Recent, Video Tutorials, Get Started, Examples, dan Documentation.

3.3 Kategori Widget

Widget pada panel kiri dikelompokkan ke dalam enam kategori utama, yaitu Data, Transform, Visualize, Model, Evaluate, dan Unsupervised. Ringkasannya disajikan pada Tabel 3.1.

Tabel 3.1 Kategori widget pada Orange

Kategori	Fungsi	Contoh widget
Data	Memuat, memeriksa, dan menyimpan data	File, CSV File Import, Datasets, Data Table, Data Info, Paint Data, Edit Domain, Color, Column Statistics, Feature Statistics, Correlations, Rank
Transform	Memilih, membersihkan, dan mengubah data	Select Columns, Select Rows, Data Sampler, Impute, Preprocess, Discretize, Continuize, Merge Data, Concatenate, Group by, Pivot Table
Visualize	Eksplorasi data secara visual dan interaktif	Scatter Plot, Box Plot, Distributions, Violin Plot, Bar Plot, Line Plot, Heat Map, Mosaic Display, Sieve Diagram, Tree Viewer
Model	Algoritma pembelajaran mesin	Tree, Random Forest, Naive Bayes, kNN, SVM, Logistic Regression, Linear Regression, Neural Network, Gradient Boosting, AdaBoost, CN2 Rule Induction, Stacking
Evaluate	Mengukur kualitas model	Test and Score, Predictions, Confusion Matrix, ROC Analysis, Lift Curve, Calibration Plot
Unsupervised	Klasterisasi dan reduksi dimensi	k-Means, Hierarchical Clustering, DBSCAN, Distances, PCA, MDS, t-SNE, Self-Organizing Map

Catatan: daftar contoh widget disusun berdasarkan dokumentasi resmi Orange dan tampilan panel widget. Ketersediaan widget dapat berbeda antarversi.

3.4 Add-on

Fitur tambahan Orange dipasang sebagai add-on melalui menu Options, lalu Add-ons. Add-on yang umum dikenal antara lain Text untuk pemrosesan teks, Image Analytics untuk data gambar, Timeseries untuk deret waktu, dan Associate untuk aturan asosiasi. Pada eksperimen ini penulis tidak memasang add-on karena klasifikasi dataset tabular dapat dikerjakan dengan widget bawaan. Pemakaian add-on akan dibahas pada tahap berikutnya.

3.5 Ciri Khas Orange

4. **Eksekusi otomatis.** Hasil widget diperbarui langsung ketika input atau pengaturannya berubah, tanpa tombol eksekusi terpisah.
5. **Visualisasi interaktif.** Data yang dipilih pada satu grafik dapat diteruskan ke widget lain untuk dianalisis lebih lanjut.
6. **Ringan dan mudah dipelajari.** Antarmuka sederhana sehingga cocok untuk eksplorasi cepat.
7. **Terhubung dengan Python.** Tersedia widget Python Script, dan Orange dapat dipakai sebagai pustaka Python.

3.6 Dataset

Dataset yang digunakan adalah Bank Marketing dari UCI Machine Learning Repository, yang berasal dari kampanye pemasaran langsung berbasis telepon pada sebuah bank di Portugal (Moro dkk., 2014). Berkas yang dipakai adalah bank-full.csv, sama dengan dataset pada eksperimen KNIME sebelumnya agar perbandingannya lebih valid. Dataset ini berisi 45.211 instans dan 17 atribut, terdiri atas 10 atribut kategorikal (termasuk target) dan 7 atribut numerik, sebagaimana dilaporkan widget Data Info. Berkas ini menggunakan tanda titik koma sebagai pemisah kolom. Daftar atribut disajikan pada tabel dibawah ini.

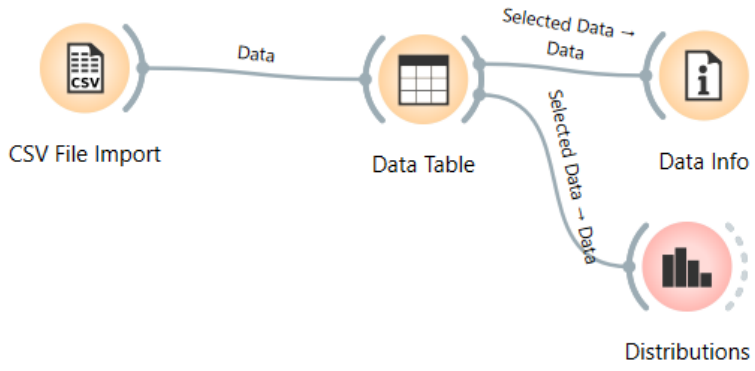
Atribut	Tipe	Keterangan
age	Numerik	Usia nasabah
job	Kategorikal	Jenis pekerjaan
marital	Kategorikal	Status pernikahan
education	Kategorikal	Tingkat pendidikan
default	Kategorikal	Apakah memiliki kredit macet
balance	Numerik	Saldo rata-rata tahunan
housing	Kategorikal	Apakah memiliki kredit perumahan
loan	Kategorikal	Apakah memiliki pinjaman pribadi
contact	Kategorikal	Jenis media komunikasi kontak
day	Numerik	Tanggal kontak terakhir dalam bulan
month	Kategorikal	Bulan kontak terakhir
duration	Numerik	Durasi kontak terakhir (detik)
campaign	Numerik	Jumlah kontak pada kampanye ini
pdays	Numerik	Jumlah hari sejak kontak pada kampanye sebelumnya (-1 berarti belum pernah dihubungi)
previous	Numerik	Jumlah kontak sebelum kampanye ini
poutcome	Kategorikal	Hasil kampanye sebelumnya
y	Kategorikal (target)	Apakah nasabah berlangganan deposito berjangka (yes/no)

Widget Data Info melaporkan bahwa tidak ada nilai hilang (missing data: none). Namun, atribut job, education, contact, dan poutcome memuat nilai unknown. Orange membaca nilai tersebut sebagai kategori biasa, bukan sebagai nilai hilang. Apabila ingin diperlakukan sebagai missing, nilainya perlu diubah melalui widget Edit Domain atau Impute.

3.7 Impor dan Eksplorasi Data

Tahap pertama adalah memuat dan memeriksa data dengan langkah-langkah berikut.

1. Menempatkan widget CSV File Import pada kanvas, memilih berkas bank-full.csv, dan mengatur pemisah (delimiter) menjadi titik koma sampai kolom terpisah dengan benar pada pratinjau.
2. Menghubungkan CSV File Import ke widget Data Table untuk melihat seluruh instans. Tabel menampilkan 45.211 baris dan 17 kolom.
3. Menghubungkan Data Table ke Data Info untuk melihat ringkasan dataset dan ke Distributions untuk melihat sebaran nilai tiap atribut, terutama atribut target y.



Widget Distributions pada atribut target y menunjukkan sebaran kelas yang tidak seimbang, sebagaimana tercantum pada tabel dibawah ini. Rasio kelas no terhadap yes adalah sekitar 7,55 : 1.

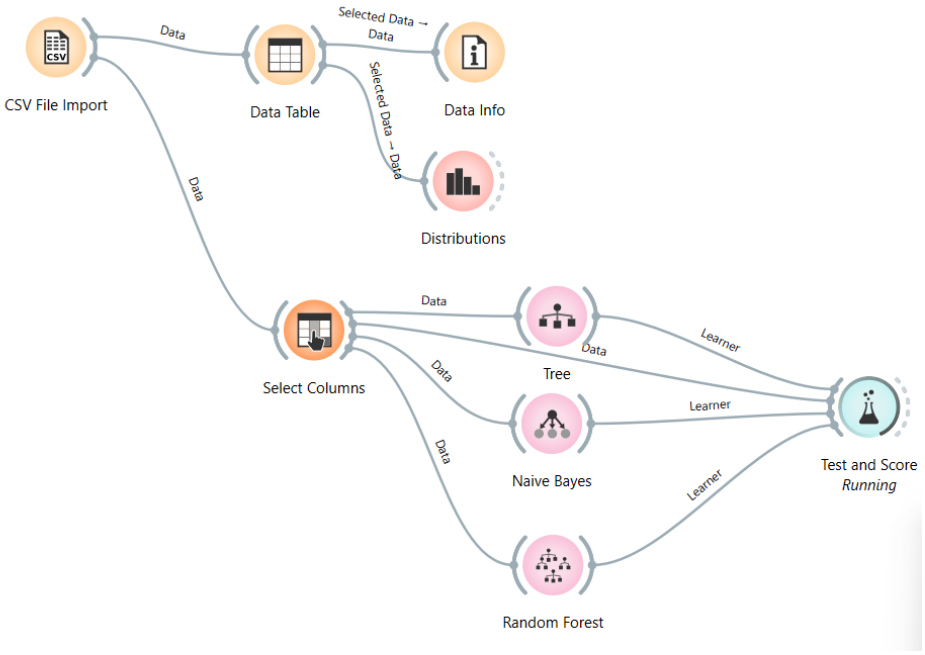
Kelas	Jumlah instans	Proporsi
no	39.922	88,30%
yes	5.289	11,70%
Total	45.211	100%

3.8 Perancangan Workflow Klasifikasi

Workflow klasifikasi dirancang dengan alur sebagai berikut.

1. Select Columns. Atribut y ditetapkan sebagai target, sedangkan 16 atribut lainnya menjadi fitur.

2. Model. Tiga algoritma dipilih dengan pengaturan bawaan Orange, yaitu Tree (pohon keputusan), Naive Bayes, dan Random Forest.
3. Test and Score. Data dari Select Columns dan ketiga model dihubungkan ke satu widget Test and Score. Metode evaluasi yang dipilih adalah Cross validation dengan 10 fold dan opsi Stratified, dengan target class yes sehingga metrik dihitung khusus untuk kelas minoritas.
4. Confusion Matrix. Widget ini dihubungkan ke Test and Score untuk melihat rincian prediksi benar dan salah pada tiap model.

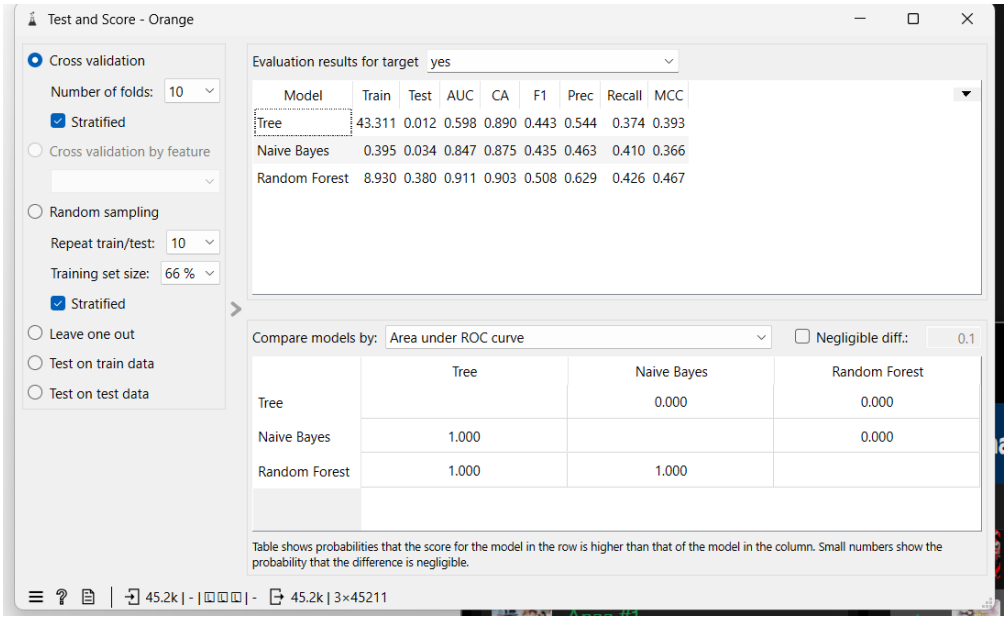


Komponen	Pengaturan
Dataset	bank-full.csv, 45.211 instans
Fitur dan target	16 fitur, target y (kelas yes sebagai kelas positif)
Algoritma	Tree, Naive Bayes, Random Forest (parameter bawaan)
Metode evaluasi	Cross validation 10 fold, stratified
Metrik	AUC, CA, F1, Precision, Recall, MCC, serta waktu latih dan uji

BAB IV HASIL DAN PEMBAHASAN

4.1 Hasil Evaluasi Model

Hasil evaluasi ketiga model pada kelas yes ditampilkan pada gambar dan dirangkum pada tabel dibawah ini.



Model	AUC	CA	F1	Precision	Recall	MCC
Tree	0,598	0,890	0,443	0,544	0,374	0,393
Naive Bayes	0,847	0,875	0,435	0,463	0,410	0,366
Random Forest	0,911	0,903	0,508	0,629	0,426	0,467

4.2 Pembahasan

Akurasi tidak cukup menggambarkan kinerja. Apabila model memprediksi seluruh nasabah sebagai no, akurasinya sudah mencapai 88,30% (39.922 dari 45.211 instans). Akurasi *Naive Bayes* (87,5%) bahkan berada di bawah angka tersebut, sedangkan *Tree* (89,0%) dan *Random Forest* (90,3%) hanya sedikit di atasnya. Akurasi sebesar itu karenanya lebih mencerminkan dominasi kelas no daripada kemampuan model.

Recall kelas *yes* rendah pada semua model. *Recall* berkisar antara 37,4% sampai 42,6%, artinya lebih dari separuh nasabah yang sebenarnya berlangganan

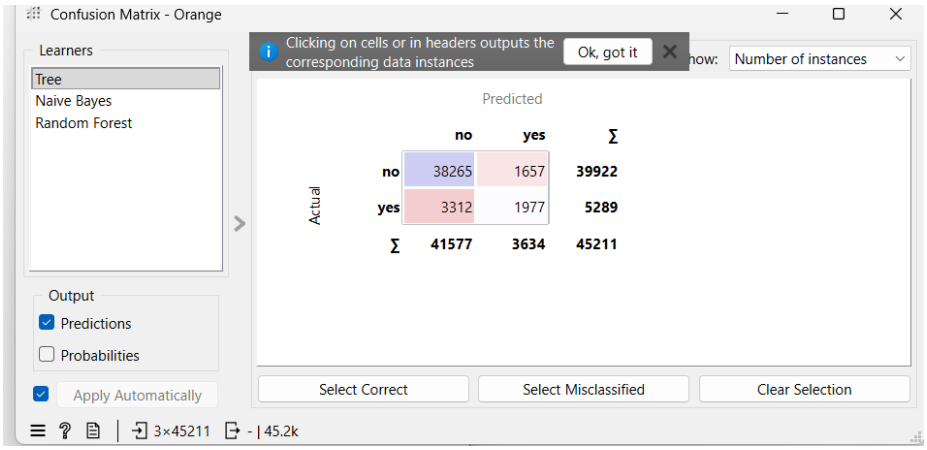
(5.289 nasabah) tidak terdeteksi. Inilah dampak ketidakseimbangan kelas pada model yang dilatih tanpa penanganan khusus.

Random Forest memberikan hasil terbaik. Model ini unggul pada AUC (0,911), F1 (0,508), precision (0,629), recall (0,426), dan MCC (0,467). Pada tabel perbandingan model berdasarkan *AUC* di *widget Test and Score*, probabilitas Random Forest lebih baik daripada Naive Bayes dan Tree bernilai 1,000, sehingga selisihnya hampir pasti nyata. Urutan kinerja berdasarkan AUC adalah Random Forest, Naive Bayes, kemudian Tree.

AUC Tree paling rendah. Nilai AUC Tree hanya 0,598 meskipun akurasinya setara model lain. Penulis menduga hal ini disebabkan pohon yang tumbuh sangat dalam pada pengaturan bawaan sehingga probabilitas prediksinya cenderung ekstrem. Dugaan ini sejalan dengan waktu latih Tree yang paling lama, tetapi belum diverifikasi dengan membatasi kedalaman pohon.

4.3 Confusion Matrix

Confusion Matrix untuk model Tree ditampilkan pada gambar dan dirangkum pada tabel dibawah ini.



Aktual \ Prediksi	no	yes	Total
no	38.265 (TN)	1.657 (FP)	39.922
yes	3.312 (FN)	1.977 (TP)	5.289
Total	41.577	3.634	45.211

Dari tabel tersebut diperoleh akurasi 89,01% ((38.265 + 1.977) / 45.211), precision 54,40% (1.977 / 3.634), dan recall 37,38% (1.977 / 5.289). Nilai ini sesuai dengan hasil pada Test and Score. Model sangat baik mengenali kelas no (38.265 dari 39.922 atau 95,85%), tetapi 3.312 nasabah yes (62,62%) salah diprediksi sebagai no.

4.4 Waktu Proses

Widget Test and Score juga melaporkan waktu latih dan waktu uji dalam satuan detik, sebagaimana pada tabel dibawah ini.

Model	Waktu latih	Waktu uji
Tree	43,311	0,012
Naive Bayes	0,395	0,034
Random Forest	8,930	0,380

Naive Bayes paling cepat dilatih, sedangkan Tree justru paling lama dilatih (43,311 detik), lebih lama dari *Random Forest*. *Random Forest* membutuhkan waktu uji terlama (0,380 detik) tetapi memberikan hasil terbaik. Angka ini berasal dari satu kali eksekusi, kemungkinan merupakan akumulasi seluruh fold, dan spesifikasi perangkat tidak dicatat, sehingga hanya layak dijadikan gambaran relatif. Untuk perbandingan yang adil dengan KNIME, pengukuran perlu diulang dengan skema evaluasi yang sama pada perangkat yang sama.

4.5 Penanganan Data Tidak Seimbang di Orange

Penulis tidak menguji balancing di Orange, tetapi hasil penelusuran pustaka menunjukkan hal-hal berikut.

1. Orange tidak menyediakan widget SMOTE bawaan. Pada halaman FAQ resminya, pengembang menyatakan bahwa terdapat alasan mengapa mereka tidak mengimplementasikan SMOTE (Orange Data Mining, n.d.).
2. Teknik oversampling dan undersampling dapat dilakukan melalui widget Python Script dengan pustaka imbalanced-learn (misalnya SMOTE dan RandomUnderSampler). SMOTE standar dirancang untuk fitur numerik

sehingga untuk dataset dengan banyak atribut kategorikal seperti bank-full.csv diperlukan varian khusus seperti SMOTE-NC. Selain itu, keluaran dari Python Script perlu diperiksa kesesuaiannya dengan domain data sebelum dihubungkan ke Test and Score.

3. Sampling sederhana dapat dilakukan dengan widget Data Sampler, dan tersedia pula add-on komunitas bernama Orange Plus yang memuat widget SMOTE (Papadopoulos, 2020). Add-on ini bukan bagian dari distribusi resmi Orange.
4. Pada KNIME, balancing sudah tersedia melalui node seperti Equal Size Sampling dan SMOTE, yang telah dicoba pada laporan sebelumnya.

Perbedaan ini menjadi salah satu pembeda penting antara kedua perangkat untuk kebutuhan data tidak seimbang.

BAB V PERBANDINGAN ORANGE DAN KNIME

5.1 Perbandingan Fitur dan Karakteristik

Perbandingan karakteristik kedua perangkat disajikan pada tabel dibawah ini. Perbandingan ini disusun berdasarkan pengalaman penulis menggunakan keduanya dan dokumentasi resmi, dan beberapa pernyataan bersifat umum.

Aspek	Orange	KNIME
Unit kerja	Widget	Node
Eksekusi	Otomatis, hasil diperbarui saat input atau pengaturan berubah	Manual, node dijalankan (execute) satu per satu atau bersamaan
Visualisasi	Sangat interaktif, data terpilih dapat diteruskan ke widget lain	Ditampilkan pada jendela tampilan node, cenderung lebih statis
Cakupan fitur	Lebih ringkas, berfokus pada data mining dan pembelajaran mesin dasar	Lebih luas, mencakup integrasi basis data, skrip Python dan R, serta pemrosesan data besar
Skala data	Data dimuat di memori, cocok untuk dataset kecil sampai menengah	Umumnya lebih siap untuk data besar dan alur kerja produksi
Kurva belajar	Lebih landai, cocok untuk pemula	Lebih curam, tetapi lebih fleksibel
Penanganan data tidak seimbang	Tidak ada widget SMOTE bawaan, perlu Python Script atau add-on komunitas	Tersedia node Equal Size Sampling dan SMOTE
Ekstensi	Add-on melalui menu Options, Add-ons	Extension dan komponen komunitas melalui KNIME Hub
Format workflow	.ows	.knwf

5.2 Perbandingan Hasil Eksperimen

Hasil model pohon keputusan pada kedua perangkat tanpa balancing ditampilkan pada tabel dibawah ini. Angka KNIME diambil dari laporan pekan ketiga.

Aspek	Decision Tree KNIME	Tree Orange
Dataset	bank-full.csv (45.211 baris)	bank-full.csv (45.211 baris)
Kolom yang dipakai	8 kolom: age, job, marital, education, balance, housing, loan, y	17 kolom: 16 fitur dan target y
Metode evaluasi	Partisi 70:30 stratified, seed 42 (data uji 13.564)	Cross validation 10 fold, stratified
Accuracy	84,4%	89,0%
Precision	30,5%	54,4%
Recall	26,5%	37,4%
F-measure (F1)	28,4%	44,3%
Waktu eksekusi	Belum diukur	43,311 detik (latih), 0,012 detik (uji)

Orange tampak menghasilkan angka yang lebih baik, tetapi selisih tersebut tidak dapat dipastikan berasal dari perangkatnya. Kedua eksperimen berbeda pada jumlah kolom yang dipakai dan pada metode evaluasi. Orange juga menyertakan atribut duration yang menurut dokumentasi dataset UCI berpengaruh kuat terhadap target dan baru diketahui setelah panggilan dilakukan, sehingga diduga ikut menaikkan hasil. Agar perbandingan valid, eksperimen KNIME perlu diulang dengan 16 fitur dan cross validation 10 fold, atau sebaliknya eksperimen Orange disesuaikan dengan skema KNIME.

5.3 Ringkasan Perbandingan

1. Orange unggul untuk eksplorasi cepat dan pembelajaran karena eksekusinya otomatis, visualisasinya interaktif, dan antarmukanya ringan.
2. KNIME unggul untuk alur kerja yang lebih kompleks karena cakupan node yang luas, kontrol eksekusi per node, dan tersedianya teknik balancing.
3. Untuk dataset tidak seimbang, KNIME lebih praktis karena balancing tersedia langsung, sedangkan di Orange diperlukan pemrograman Python.

BAB VI KESIMPULAN DAN SARAN

6.1 Kesimpulan

1. Orange Data Mining berhasil dipasang pada Windows menggunakan installer standalone dan dapat langsung digunakan tanpa konfigurasi tambahan.
2. Orange menyediakan enam kategori widget utama (Data, Transform, Visualize, Model, Evaluate, Unsupervised) yang mencakup alur data mining dari pemuatan data hingga evaluasi model.
3. Pada dataset bank-full.csv yang tidak seimbang (no 88,30%, yes 11,70%), Random Forest memberikan hasil terbaik dengan AUC 0,911, F1 0,508, dan recall 0,426 pada kelas yes. Recall seluruh model masih di bawah 43%, sehingga akurasi saja tidak memadai untuk menilai kinerja.
4. Orange tidak memiliki widget SMOTE bawaan, sedangkan KNIME menyediakan teknik balancing langsung. Orange lebih ringan dan interaktif, sedangkan KNIME lebih luas dan terkontrol.
5. Perbandingan hasil numerik dengan KNIME belum sepenuhnya setara karena perbedaan kolom yang dipakai dan metode evaluasi.

6.2 Saran

4. Mengulang eksperimen KNIME dan Orange dengan fitur dan skema evaluasi yang sama, serta mengukur waktu eksekusi pada perangkat yang sama.
5. Mencoba pembatasan kedalaman pada Tree untuk memeriksa dugaan overfitting, dan menguji balancing di Orange melalui Python Script atau add-on.
6. Melanjutkan eksplorasi Orange ke klasterisasi, asosiasi, dan regresi, serta ke dataset teks, gambar, dan deret waktu dengan add-on yang sesuai.

DAFTAR PUSTAKA

Demšar, J., Curk, T., Erjavec, A., Gorup, Č., Hočevar, T., Milutinović, M., ... Zupan, B. (2013). Orange: Data mining toolbox in Python. *Journal of Machine Learning Research*, 14, 2349–2353.

Moro, S., Cortez, P., & Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems*, 62, 22–31.

Orange Data Mining. (n.d.). *Download Orange*. https://orangedatamining.com/download/

Orange Data Mining. (n.d.). *Frequently asked questions*. https://orangedatamining.com/faq/

Papadopoulos, P. (2020). *Orange Plus: Add-on for Orange3 with custom widgets*. https://github.com/panatronic-git/orange-plus

Python Package Index. (n.d.). *Orange3*. https://pypi.org/project/Orange3/

UCI Machine Learning Repository. (n.d.). *Bank Marketing dataset*. https://archive.ics.uci.edu/dataset/222/bank+marketing