EKSPLORASI FITUR ORANGE DATA MINING DAN PERBANDINGANNYA DENGAN KNIME

LAPORAN

Raditya Mulya Akbar

425 23 011

PROGRAM STUDI S1 TERAPAN TEKNIK KOMPUTER DAN JARINGAN

JURUSAN TEKNIK INFORMATIKA DAN KOMPUTER

POLITEKNIK NEGERI UJUNG PANDANG

MAKASSAR

2026

DAFTAR ISI

DAFTAR ISI.....i
BAB I PENDAHULUAN.....1
1.1 Latar Belakang.....1
1.2 Tujuan.....1
1.3 Ruang Lingkup dan Batasan.....2
BAB II LANDASAN TEORI.....3
2.1 Orange Data Mining.....3
2.2 KNIME.....3
2.3 Klasifikasi dan Metrik Evaluasi.....3
2.4 Data Tidak Seimbang dan Teknik Penanganannya.....4
BAB III METODE PRAKTIKUM.....5
3.1 Instalasi pada Windows.....5
3.2 Antarmuka Orange.....5
3.3 Kategori Widget.....6
3.4 Add-on.....6
3.5 Ciri Khas Orange.....7
3.6 Widget Python Script.....7
3.7 Dataset.....7
3.8 Impor dan Eksplorasi Data.....8
3.9 Eksperimen 1: Rancangan Perbandingan Tiga Algoritma.....9
3.10 Eksperimen 2: Rancangan Penanganan Data Tidak Seimbang.....10
3.10.1 Pemasangan Pustaka imbalanced-learn.....10
3.10.2 Rancangan Eksperimen.....11
3.10.3 Pelaksanaan Tiap Skenario.....13
BAB IV HASIL DAN PEMBAHASAN.....15
4.1 Eksperimen 1: Hasil Evaluasi Tiga Algoritma.....15
4.2 Eksperimen 1: Confusion Matrix Model Tree.....16
4.3 Eksperimen 2: Hasil Penanganan Data Tidak Seimbang.....17
4.4 Catatan Penanganan Data Tidak Seimbang di Orange.....19

4.5 Perbandingan Fitur dan Karakteristik.....20
4.6 Perbandingan Hasil Eksperimen Balancing.....21
4.7 Ringkasan Perbandingan.....23
BAB V KESIMPULAN DAN SARAN.....24
5.1 Kesimpulan.....24
5.2 Saran.....24
DAFTAR PUSTAKA.....26

BAB I PENDAHULUAN

1.1 Latar Belakang

Data mining adalah proses menemukan pola dan pengetahuan yang bermanfaat dari kumpulan data berukuran besar. Untuk mengerjakannya tersedia berbagai perangkat lunak berbasis pemrograman visual, yaitu perangkat yang menyusun alur analisis dengan menghubungkan komponen-komponen pada sebuah kanvas tanpa harus menulis banyak kode. Dua di antaranya adalah KNIME dan Orange Data Mining.

Dalam program magang di Center for Applied ICT Research (CAIR), penulis ditugaskan mempelajari sejumlah perangkat bantu analisis data dan menyusun tutorial lengkap beserta dataset dan video pembelajarannya. Pada tahap sebelumnya penulis telah mengeksplorasi KNIME, mulai dari persiapan data, pengolahan berbagai tipe data, hingga penanganan dataset tidak seimbang. Pada tahap ini penulis mempelajari Orange Data Mining dengan dua sasaran, yaitu mengenal fitur-fiturnya dan membandingkannya dengan KNIME dari sisi data mining.

Salah satu catatan penting dari tahap sebelumnya adalah penanganan data tidak seimbang. KNIME menyediakan node balancing, sedangkan Orange tidak memiliki widget SMOTE bawaan. Oleh karena itu, selain mengeksplorasi fitur dasar dan klasifikasi, laporan ini juga menguji apakah balancing dapat dilakukan di Orange melalui widget Python Script dengan pustaka imbalanced-learn.

1.2 Tujuan

1. Memasang dan mengenali antarmuka serta kategori widget pada Orange Data Mining.
2. Meninjau fitur-fitur utama Orange untuk keperluan data mining.
3. Mengimplementasikan alur klasifikasi pada dataset Bank Marketing menggunakan Orange dan mengevaluasi hasilnya.
4. Menerapkan dan mengevaluasi teknik penanganan data tidak seimbang di Orange (undersampling acak dan SMOTE-NC) melalui widget Python Script.
5. Membandingkan karakteristik, fitur, dan hasil Orange dengan KNIME.

1.3 Ruang Lingkup dan Batasan

Laporan ini mencakup instalasi Orange pada sistem operasi Windows, tinjauan kategori widget, dan dua eksperimen pada dataset bank-full.csv. Eksperimen pertama membandingkan tiga algoritma klasifikasi (Tree, Naive Bayes, dan Random Forest) dengan cross validation. Eksperimen kedua menguji tiga skenario penanganan data tidak seimbang (tanpa balancing, undersampling acak, dan SMOTE-NC) dengan algoritma Tree pada pembagian data latih dan uji 70:30. Batasan laporan ini adalah sebagai berikut.

1. Klasterisasi, asosiasi, regresi, dan pemakaian add-on belum dibahas dan akan dilaporkan pada tahap berikutnya.
2. Eksperimen penanganan data tidak seimbang hanya memakai satu algoritma (Tree dengan parameter bawaan), satu kali pembagian data, dan satu nilai seed, sehingga selisih kecil antarskenario belum tentu bermakna.
3. Perbandingan dengan KNIME difokuskan pada pola hasil, karena kedua eksperimen tidak identik dalam seluruh pengaturannya.

BAB II LANDASAN TEORI

2.1 Orange Data Mining

Orange adalah perangkat lunak data mining berbasis komponen yang bersifat open source. Perangkat ini menyediakan teknik visualisasi data, eksplorasi, prapemrosesan, dan pemodelan yang dapat digunakan melalui antarmuka grafis, dan juga dapat dipakai sebagai modul pada bahasa pemrograman Python (Demšar dkk., 2013). Pada antarmuka grafis, pengguna menyusun alur kerja (workflow) dengan menyeret widget ke kanvas lalu menghubungkannya dengan garis. Setiap widget menjalankan satu fungsi tertentu, misalnya memuat data, memilih kolom, melatih model, atau menampilkan grafik.

2.2 KNIME

KNIME adalah platform analitik data visual yang menyusun alur kerja dari node. Setiap node melakukan satu operasi dan dijalankan (execute) secara terpisah sehingga hasil antarnode dapat diperiksa satu per satu. Pada eksplorasi sebelumnya, penulis menggunakan KNIME untuk persiapan data dan eksperimen balancing pada dataset Bank Marketing, sehingga hasilnya dapat dijadikan pembanding.

2.3 Klasifikasi dan Metrik Evaluasi

Klasifikasi adalah proses melatih model untuk memprediksi kelas dari suatu data berdasarkan atribut-atributnya. Kinerja model dinilai dari confusion matrix, yaitu tabel yang membandingkan kelas sebenarnya dengan kelas hasil prediksi. Untuk kelas positif (pada penelitian ini kelas yes), empat nilai yang digunakan adalah TP (positif terprediksi benar), TN (negatif terprediksi benar), FP (negatif terprediksi positif), dan FN (positif terprediksi negatif). Metrik yang dipakai pada laporan ini adalah sebagai berikut.

$$\textit{Classification Accuracy (CA)} = (TP + TN) / (TP + TN + FP + FN)$$

$$\textit{Precision} = TP / (TP + FP)$$

$$\textit{Recall} = TP / (TP + FN)$$

$$F1 = 2 \times \textit{Precision} \times \textit{Recall} / (\textit{Precision} + \textit{Recall})$$

AUC (Area Under the ROC Curve) mengukur kemampuan model membedakan kelas positif dan negatif pada berbagai ambang probabilitas,

sedangkan MCC (Matthews Correlation Coefficient) merangkum seluruh isi confusion matrix menjadi satu angka yang lebih tahan terhadap ketidakseimbangan kelas. Evaluasi pada eksperimen pertama memakai k-fold cross validation, yaitu data dibagi menjadi k bagian yang bergantian menjadi data uji, dengan opsi stratified untuk menjaga proporsi kelas pada tiap bagian. Evaluasi pada eksperimen kedua memakai pembagian hold-out, yaitu data dibagi sekali menjadi data latih dan data uji yang terpisah.

2.4 Data Tidak Seimbang dan Teknik Penanganannya

Dataset dikatakan tidak seimbang apabila jumlah data pada satu kelas jauh lebih banyak daripada kelas lainnya. Pada kondisi ini, akurasi dapat menyesatkan karena model yang selalu memprediksi kelas mayoritas pun akan tampak akurat. Karena itu, evaluasi sebaiknya berfokus pada recall, precision, dan F1 untuk kelas minoritas. Dua teknik penyeimbangan yang digunakan pada laporan ini adalah sebagai berikut.

1. **Undersampling acak** membuang sebagian data kelas mayoritas secara acak sampai jumlahnya sama dengan kelas minoritas. Teknik ini sederhana, tetapi data yang dibuang berarti informasinya hilang.
2. **SMOTE** (Synthetic Minority Over-sampling Technique) membuat data sintetis kelas minoritas dengan menginterpolasi antara sebuah data minoritas dan salah satu tetangga terdekatnya (Chawla dkk., 2002). **SMOTE-NC** adalah varian untuk dataset yang memuat atribut numerik sekaligus kategorikal: atribut numerik diinterpolasi, sedangkan atribut kategorikal diisi dengan kategori yang paling sering muncul pada tetangga terdekat. Teknik ini tersedia pada pustaka imbalanced-learn (Lemaître dkk., 2017).

Teknik penyeimbangan hanya boleh diterapkan pada **data latih**. Data uji harus dibiarkan apa adanya agar mencerminkan distribusi kelas yang sebenarnya. Apabila balancing dilakukan pada seluruh data sebelum pembagian, data sintetis atau duplikat dapat masuk ke data uji dan hasil evaluasi menjadi terlalu optimistis.

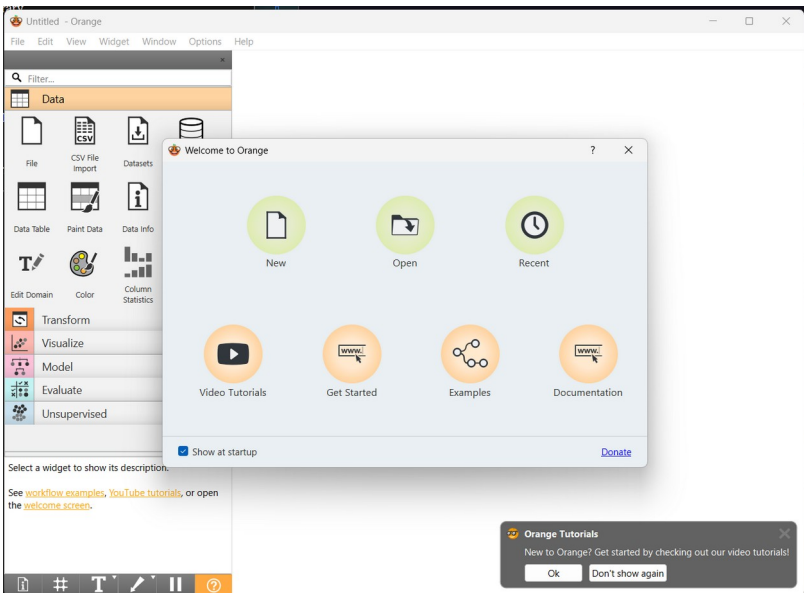
BAB III METODE PRAKTIKUM

3.1 Instalasi pada Windows

Orange dapat dipasang dengan beberapa cara, yaitu installer standalone dari situs resmi, melalui pip, atau melalui distribusi Anaconda. Penulis menggunakan installer standalone karena paling sederhana. Installer ini sudah menyertakan Python dan pustaka yang dibutuhkan sehingga tidak diperlukan instalasi tambahan. Langkah-langkahnya adalah sebagai berikut.

1. Mengunduh installer Orange untuk Windows dari halaman unduhan resmi (orangedatamining.com/download).
2. Menjalankan installer dan mengikuti wizard dengan pengaturan bawaan sampai proses instalasi selesai.
3. Membuka aplikasi Orange dari Start Menu. Pada pembukaan pertama muncul jendela Welcome to Orange.

Sebagai alternatif, Orange dapat dipasang pada lingkungan Python dengan perintah pip install orange3 dan dijalankan dengan perintah orange-canvas (Python Package Index, n.d.). Instalasi pada penelitian ini berhasil dan jendela Welcome tampil normal seperti pada gambar dibawah ini.



3.2 Antarmuka Orange

Antarmuka Orange terdiri atas tiga bagian utama. Panel widget di sisi kiri memuat widget yang dikelompokkan per kategori dan dilengkapi kolom pencarian

(Filter). Kanvas di sisi kanan menjadi tempat menyusun workflow. Menu di bagian atas menyediakan pengaturan seperti File, Edit, View, Widget, Window, Options, dan Help. Jendela Welcome menyediakan akses cepat ke New (workflow baru), Open, Recent, Video Tutorials, Get Started, Examples, dan Documentation.

3.3 Kategori Widget

Widget pada panel kiri dikelompokkan ke dalam enam kategori utama, yaitu Data, Transform, Visualize, Model, Evaluate, dan Unsupervised. Ringkasannya disajikan pada tabel dibawah ini.

Kategori	Fungsi	Contoh widget
Data	Memuat, memeriksa, dan menyimpan data	File, CSV File Import, Datasets, Data Table, Data Info, Paint Data, Edit Domain, Color, Column Statistics, Feature Statistics, Correlations, Rank
Transform	Memilih, membersihkan, dan mengubah data	Select Columns, Select Rows, Data Sampler, Impute, Preprocess, Discretize, Continuize, Merge Data, Concatenate, Group by, Pivot Table, Python Script
Visualize	Eksplorasi data secara visual dan interaktif	Scatter Plot, Box Plot, Distributions, Violin Plot, Bar Plot, Line Plot, Heat Map, Mosaic Display, Sieve Diagram, Tree Viewer
Model	Algoritma pembelajaran mesin	Tree, Random Forest, Naive Bayes, kNN, SVM, Logistic Regression, Linear Regression, Neural Network, Gradient Boosting, AdaBoost, CN2 Rule Induction, Stacking
Evaluate	Mengukur kualitas model	Test and Score, Predictions, Confusion Matrix, ROC Analysis, Lift Curve, Calibration Plot
Unsupervised	Klasterisasi dan reduksi dimensi	k-Means, Hierarchical Clustering, DBSCAN, Distances, PCA, MDS, t-SNE, Self-Organizing Map

Catatan: daftar contoh widget disusun berdasarkan dokumentasi resmi Orange dan tampilan panel widget. Ketersediaan widget dapat berbeda antarversi.

3.4 Add-on

Fitur tambahan Orange dipasang sebagai add-on melalui menu Options, lalu Add-ons. Add-on yang umum dikenal antara lain Text untuk pemrosesan teks, Image Analytics untuk data gambar, Timeseries untuk deret waktu, dan Associate untuk aturan asosiasi. Pada eksperimen ini penulis tidak memasang add-on karena klasifikasi dataset tabular dapat dikerjakan dengan widget bawaan. Pustaka Python

tambahan (imbalanced-learn) dipasang secara terpisah, Pemakaian add-on akan dibahas pada tahap berikutnya.

3.5 Ciri Khas Orange

1. **Eksekusi otomatis.** Hasil widget diperbarui langsung ketika input atau pengaturannya berubah, tanpa tombol eksekusi terpisah.
2. **Visualisasi interaktif.** Data yang dipilih pada satu grafik dapat diteruskan ke widget lain untuk dianalisis lebih lanjut.
3. **Ringan dan mudah dipelajari.** Antarmuka sederhana sehingga cocok untuk eksplorasi cepat.
4. **Terhubung dengan Python.** Tersedia widget Python Script, dan Orange dapat dipakai sebagai pustaka Python.

3.6 Widget Python Script

Widget Python Script memungkinkan pengguna menjalankan kode *Python* di dalam *workflow*. Pada versi yang digunakan, editor menampilkan fungsi *python_script*(*in_data*) yang mengembalikan out_data, out_learner, out_classifier, dan *out_object*. Kode ditulis pada badan fungsi tersebut: data masukan dibaca dari variabel *in_data* (tabel *Orange*), dan data hasil diserahkan ke *widget* berikutnya melalui variabel *out_data*. Di bawah editor terdapat *Console* yang menampilkan keluaran perintah *print* dan pesan kesalahan. *Widget* ini menjadi sarana utama untuk menerapkan teknik *balancing*.

3.7 Dataset

Dataset yang digunakan adalah *Bank Marketing* dari *UCI Machine Learning Repository*, yang berasal dari kampanye pemasaran langsung berbasis telepon pada sebuah bank di Portugal (Moro dkk., 2014). Berkas yang dipakai adalah bank-full.csv, sama dengan *dataset* pada eksperimen *KNIME* sebelumnya agar perbandingannya lebih valid. *Dataset* ini berisi 45.211 *instance* dan 17 atribut, terdiri atas 10 atribut kategorikal (termasuk target) dan 7 atribut numerik, sebagaimana dilaporkan *widget* Data Info. Berkas ini menggunakan tanda titik koma sebagai pemisah kolom. Daftar atribut disajikan pada tabel dibawah ini.

Atribut	Tipe	Keterangan
age	Numerik	Usia nasabah
job	Kategorikal	Jenis pekerjaan
marital	Kategorikal	Status pernikahan
education	Kategorikal	Tingkat pendidikan
default	Kategorikal	Apakah memiliki kredit macet
balance	Numerik	Saldo rata-rata tahunan
housing	Kategorikal	Apakah memiliki kredit perumahan
loan	Kategorikal	Apakah memiliki pinjaman pribadi
contact	Kategorikal	Jenis media komunikasi kontak
day	Numerik	Tanggal kontak terakhir dalam bulan
month	Kategorikal	Bulan kontak terakhir
duration	Numerik	Durasi kontak terakhir (detik)
campaign	Numerik	Jumlah kontak pada kampanye ini
pdays	Numerik	Jumlah hari sejak kontak pada kampanye sebelumnya (-1 berarti belum pernah dihubungi)
previous	Numerik	Jumlah kontak sebelum kampanye ini
poutcome	Kategorikal	Hasil kampanye sebelumnya
y	Kategorikal (target)	Apakah nasabah berlangganan deposito berjangka (yes/no)

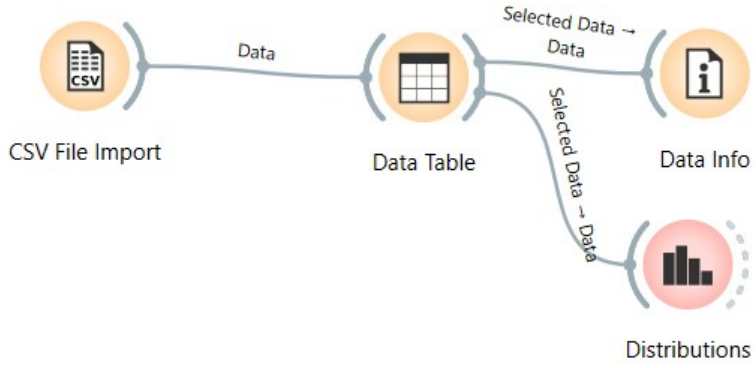
Widget Data Info melaporkan bahwa tidak ada nilai hilang (missing data: none). Namun, atribut *job*, *education*, *contact*, dan =memuat nilai unknown. Orange membaca nilai tersebut sebagai kategori biasa, bukan sebagai nilai hilang. Apabila ingin diperlakukan sebagai missing, nilainya perlu diubah melalui widget Edit Domain atau Impute.

3.8 Impor dan Eksplorasi Data

Tahap pertama adalah memuat dan memeriksa data dengan langkah berikut.

1. Menempatkan widget CSV File Import pada kanvas, memilih berkas bank-full.csv, dan mengatur pemisah (delimiter) menjadi titik koma sampai kolom terpisah dengan benar pada pratinjau.
2. Menghubungkan CSV File Import ke widget Data Table untuk melihat seluruh instans. Tabel menampilkan 45.211 baris dan 17 kolom.

3. Menghubungkan Data Table ke Data Info untuk melihat ringkasan dataset dan ke Distributions untuk melihat sebaran nilai tiap atribut, terutama atribut target y.



Widget Distributions pada atribut target y menunjukkan sebaran kelas yang tidak seimbang, sebagaimana tercantum pada tabel dibawah ini. Rasio kelas no terhadap yes adalah sekitar 7,55 : 1.

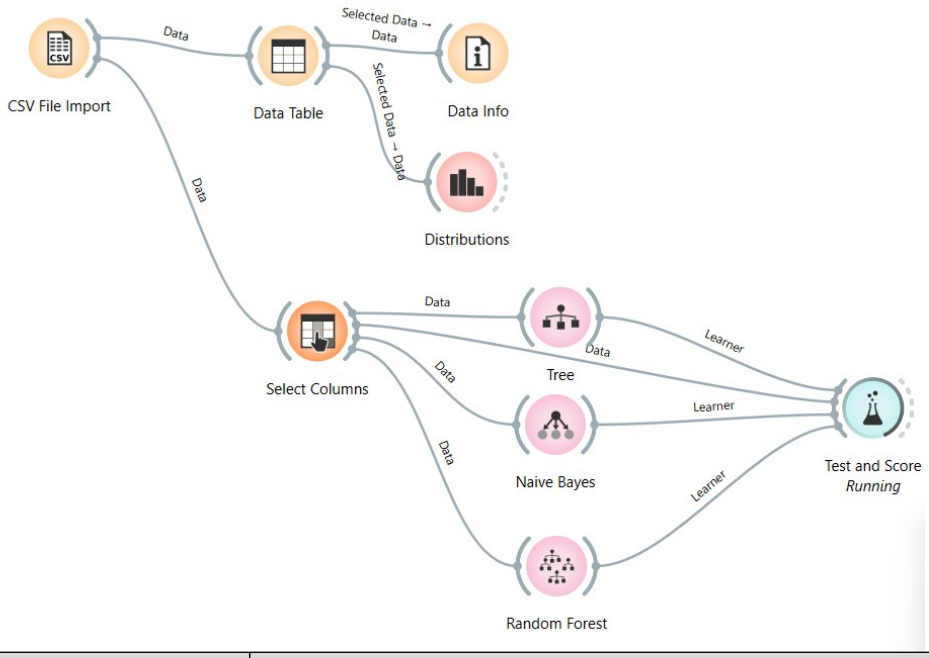
Kelas	Jumlah instans	Proporsi
no	39.922	88,30%
yes	5.289	11,70%
Total	45.211	100%

3.9 Eksperimen 1: Rancangan Perbandingan Tiga Algoritma

Eksperimen pertama bertujuan melihat kinerja dasar tiga algoritma klasifikasi pada seluruh atribut. Workflow dirancang dengan alur sebagai berikut.

1. Select Columns. Atribut y ditetapkan sebagai target, sedangkan 16 atribut lainnya menjadi fitur.
2. Model. Tiga algoritma dipilih dengan pengaturan bawaan Orange, yaitu Tree (pohon keputusan), Naive Bayes, dan Random Forest.
3. Test and Score. Data dari Select Columns dan ketiga model dihubungkan ke satu widget Test and Score. Metode evaluasi yang dipilih adalah Cross validation dengan 10 fold dan opsi Stratified, dengan target class yes sehingga metrik dihitung khusus untuk kelas minoritas.

4. Confusion Matrix. Widget ini dihubungkan ke Test and Score untuk melihat rincian prediksi benar dan salah pada tiap model.



Komponen	Pengaturan
Dataset	bank-full.csv, 45.211 instans
Fitur dan target	16 fitur, target y (kelas yes sebagai kelas positif)
Algoritma	Tree, Naive Bayes, Random Forest (parameter bawaan)
Metode evaluasi	Cross validation 10 fold, stratified
Metrik	AUC, CA, F1, Precision, Recall, MCC

3.10 Eksperimen 2: Rancangan Penanganan Data Tidak Seimbang

Eksperimen kedua menguji tiga skenario penanganan data tidak seimbang pada Orange, yang meniru tiga skenario pada eksperimen KNIME sebelumnya: tanpa balancing, undersampling (padanan Equal Size Sampling), dan SMOTE.

3.10.1 Pemasangan Pustaka imbalanced-learn

Untuk memeriksa ketersediaan pustaka, penulis menjalankan perintah import imblearn pada widget Python Script. Console menampilkan pesan ModuleNotFoundError: No module named 'imblearn', yang menunjukkan bahwa pustaka belum tersedia pada installer standalone. Lokasi interpreter Python milik Orange diperoleh dengan mencetak sys.executable, yang menghasilkan folder instalasi Orange (D:\Orange). Pustaka kemudian dipasang menggunakan

python.exe pada folder yang sama melalui Command Prompt. Sebelum pemasangan, penulis menjalankan perintah dengan opsi --dry-run untuk melihat paket apa saja yang akan berubah.

```
"D:\Orange\python.exe" -m pip install imbalanced-learn --dry-run
"D:\Orange\python.exe" -m pip install imbalanced-learn
```

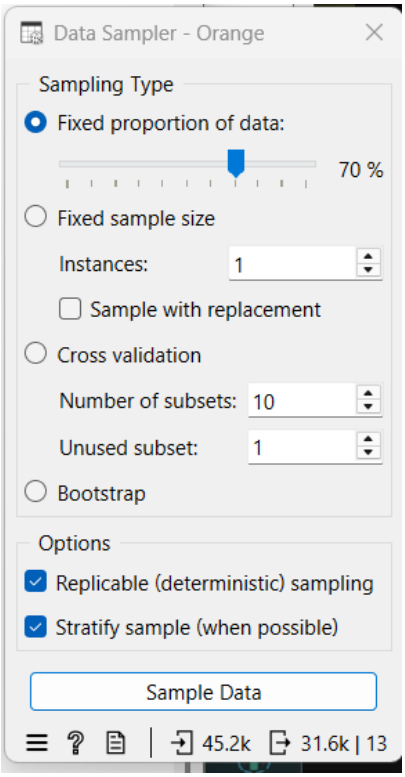
Hasil dry-run menunjukkan bahwa hanya dua paket baru yang akan dipasang, sedangkan paket lain yang dibutuhkan sudah terpenuhi oleh instalasi Orange (Tabel 3.5). Dengan demikian pemasangan tidak mengubah versi pustaka bawaan Orange. Setelah pemasangan selesai (pesan Successfully installed), Orange ditutup dan dibuka kembali, lalu perintah pemeriksaan dijalankan ulang dan Console menampilkan versi 0.14.2.

Tabel 3.5 Paket yang terlibat pada pemasangan imbalanced-learn

Paket	Versi	Status
imbalanced-learn	0.14.2	Baru dipasang
sklearn-compat	0.1.6	Baru dipasang
numpy	2.1.3	Sudah ada, tidak berubah
scipy	1.13.1	Sudah ada, tidak berubah
scikit-learn	1.5.2	Sudah ada, tidak berubah
joblib	1.5.3	Sudah ada, tidak berubah
threadpoolctl	3.6.0	Sudah ada, tidak berubah

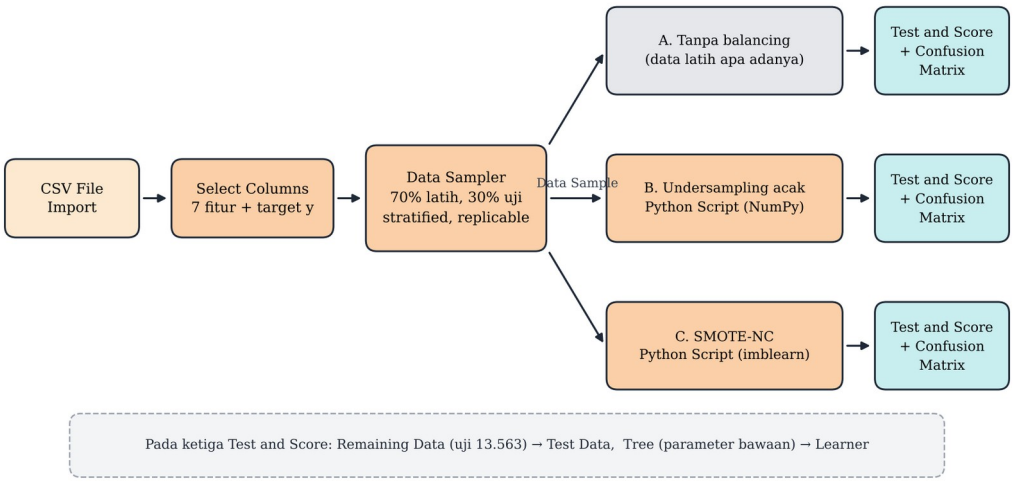
3.10.2 Rancangan Eksperimen

Agar sebanding dengan eksperimen KNIME, eksperimen kedua memakai pengaturan yang sama dengan KNIME sedapat mungkin. Atribut yang dipakai dibatasi menjadi 7 fitur (age, job, marital, education, balance, housing, dan loan) ditambah target y, melalui widget Select Columns. Data dibagi dengan widget Data Sampler menjadi 70% data latih dan 30% data uji dengan opsi Stratify sample dan Replicable (deterministic) sampling aktif (Gambar 3.4). Satu Data Sampler dipakai oleh ketiga skenario sehingga ketiganya memakai data latih dan data uji yang sama.



Gambar 3.4 Pengaturan widget Data Sampler

Balancing hanya diterapkan pada data latih (keluaran Data Sample). Data uji (keluaran Remaining Data) tidak diubah dan dihubungkan ke input Test Data pada widget Test and Score, dengan metode evaluasi Test on test data. Model yang dipakai adalah Tree dengan parameter bawaan dan target class adalah yes. Skema workflow disajikan pada Gambar 3.5, sedangkan konfigurasi dan komposisi data ditunjukkan pada Tabel 3.6 dan Tabel 3.7.



Gambar 3.5 Skema workflow eksperimen balancing pada Orange

Tabel 3.6 Konfigurasi eksperimen 2

Komponen	Pengaturan
Atribut	7 fitur (age, job, marital, education, balance, housing, loan) dan target y
Pembagian data	Data Sampler, fixed proportion 70%, stratified, replicable
Algoritma	Tree (parameter bawaan)
Metode evaluasi	Test on test data, target class yes
Skenario	A: tanpa balancing; B: undersampling acak; C: SMOTE-NC
Penerapan balancing	Hanya pada data latih; data uji tidak diubah

Tabel 3.7 Komposisi data latih dan data uji

Data	Kelas no	Kelas yes	Total
Latih, skenario A	27.946	3.702	31.648
Latih, skenario B	3.702	3.702	7.404
Latih, skenario C	27.946	27.946	55.892
Uji, semua skenario	11.976	1.587	13.563

3.10.3 Pelaksanaan Tiap Skenario

Skenario A (tanpa balancing). Keluaran Data Sample dihubungkan langsung ke input Data pada Test and Score, tanpa pemrosesan tambahan. Skenario ini menjadi baseline.

Skenario B (undersampling acak). Keluaran Data Sample diproses lebih dahulu oleh widget Python Script. Kelas mayoritas (no) dipilih secara acak tanpa pengembalian sebanyak jumlah kelas minoritas (yes), kemudian digabung dengan seluruh data yes. Hasilnya adalah 3.702 data tiap kelas atau 7.404 data latih. Kode yang digunakan adalah sebagai berikut.

```
import numpy as np

rng = np.random.default_rng(42)
y = in_data.Y
yes = in_data.domain.class_var.values.index("yes")
idx_yes = np.where(y == yes)[0]
idx_no = np.where(y != yes)[0]
keep_no = rng.choice(idx_no, size=len(idx_yes), replace=False)
keep = np.sort(np.concatenate([idx_yes, keep_no]))

out_data = in_data[keep]
print("yes:", len(idx_yes), "no sebelum:", len(idx_no), "total
sesudah:", len(out_data))
```

Skenario C (SMOTE-NC). Karena dataset memuat atribut kategorikal, digunakan SMOTE-NC dan bukan SMOTE biasa. Indeks atribut kategorikal ditentukan otomatis dari domain data, dan Console menampilkan indeks [1, 2, 3, 5, 6] yang sesuai dengan atribut job, marital, education, housing, dan loan. Pengaturan bawaan sampling_strategy menyamakan jumlah kelas minoritas dengan kelas mayoritas. Console menampilkan jumlah kelas sebelum [27.946, 3.702] dan sesudah [27.946, 27.946], sehingga data latih menjadi 55.892 baris. Kode yang digunakan adalah sebagai berikut.

```
import numpy as np
from Orange.data import Table
from imblearn.over_sampling import SMOTENC

X = in_data.X
y = in_data.Y.astype(int)
cat_idx = [i for i, a in enumerate(in_data.domain.attributes) if
a.is_discrete]

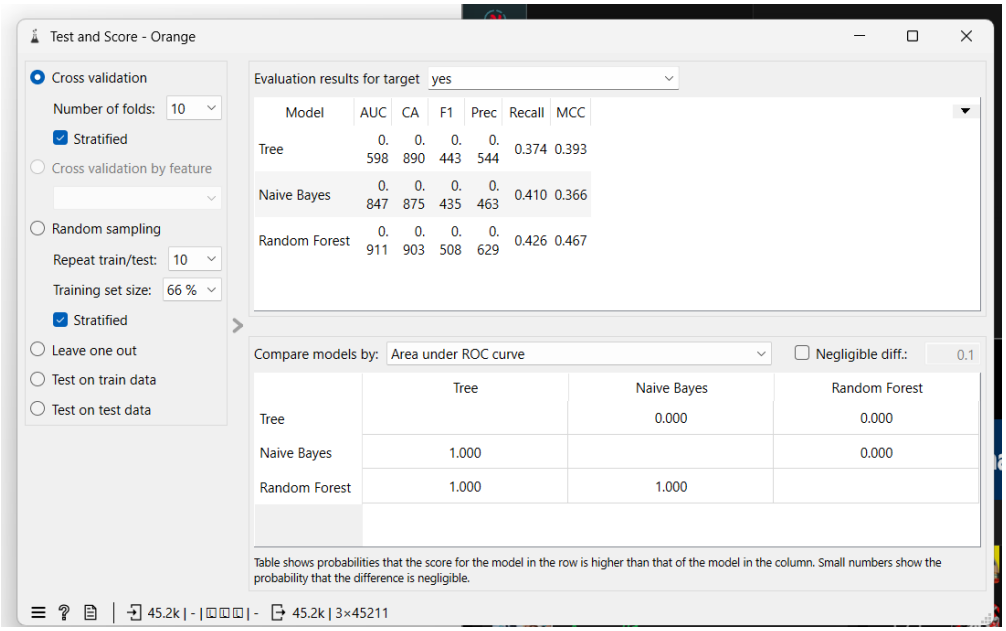
X_res, y_res = SMOTENC(categorical_features=cat_idx,
random_state=42).fit_resample(X, y)

out_data = Table.from_numpy(in_data.domain, X_res,
y_res.astype(float))
print("kolom kategorikal:", cat_idx)
print("sebelum:", np.bincount(y), "sesudah:",
np.bincount(y_res))
```

BAB IV HASIL DAN PEMBAHASAN

4.1 Eksperimen 1: Hasil Evaluasi Tiga Algoritma

Hasil evaluasi ketiga model pada kelas yes ditampilkan pada gambar dan dirangkum pada tabel dibawah imi.



Model	AUC	CA	F1	Precision	Recall	MCC
Tree	0,598	0,890	0,443	0,544	0,374	0,393
Naive Bayes	0,847	0,875	0,435	0,463	0,410	0,366
Random Forest	0,911	0,903	0,508	0,629	0,426	0,467

Akurasi tidak cukup menggambarkan kinerja**.** Apabila model memprediksi seluruh nasabah sebagai no, akurasinya sudah mencapai 88,30% (39.922 dari 45.211 instans). Akurasi Naive Bayes (87,5%) bahkan berada di bawah angka tersebut, sedangkan Tree (89,0%) dan Random Forest (90,3%) hanya sedikit di atasnya. Akurasi sebesar itu lebih mencerminkan dominasi kelas no daripada kemampuan model.

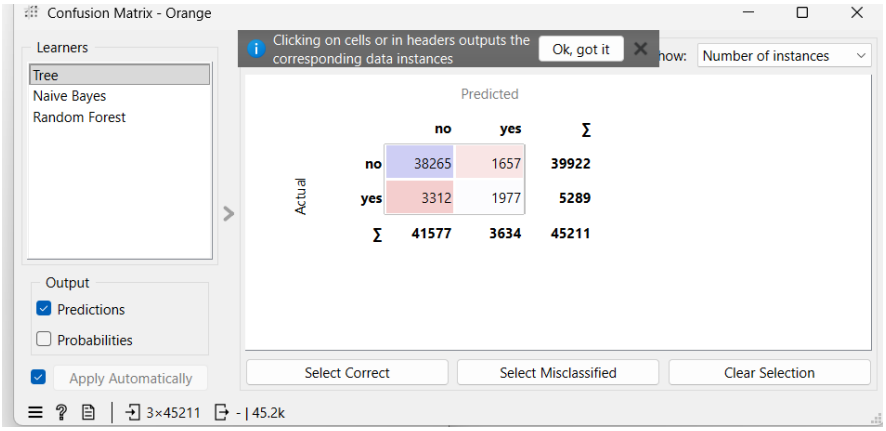
Recall kelas yes rendah pada semua model**.** Recall berkisar antara 37,4% sampai 42,6%, artinya lebih dari separuh nasabah yang sebenarnya berlangganan (5.289 nasabah) tidak terdeteksi. Inilah dampak ketidakseimbangan kelas pada model yang dilatih tanpa penanganan khusus.

Random Forest memberikan hasil terbaik. Model ini unggul pada AUC (0,911), F1 (0,508), precision (0,629), recall (0,426), dan MCC (0,467). Pada tabel perbandingan model berdasarkan AUC di widget Test and Score, probabilitas Random Forest lebih baik daripada Naive Bayes dan Tree bernilai 1,000, sehingga selisihnya hampir pasti nyata.

AUC Tree paling rendah. Nilai AUC Tree hanya 0,598 meskipun akurasinya setara model lain. Penulis menduga hal ini disebabkan pohon yang tumbuh sangat dalam pada pengaturan bawaan sehingga probabilitas prediksinya cenderung ekstrem. Dugaan ini belum diverifikasi dengan membatasi kedalaman pohon.

4.2 Eksperimen 1: Confusion Matrix Model Tree

Confusion Matrix untuk model Tree ditampilkan pada gambar dan dirangkum pada tabel dibawah ini.



Aktual \ Prediksi	no	yes	Total
No.	38.265 (TN)	1.657 (FP)	39.922
Yes	3.312 (FN)	1.977 (TP)	5.289
Total	41.577	3.634	45.211

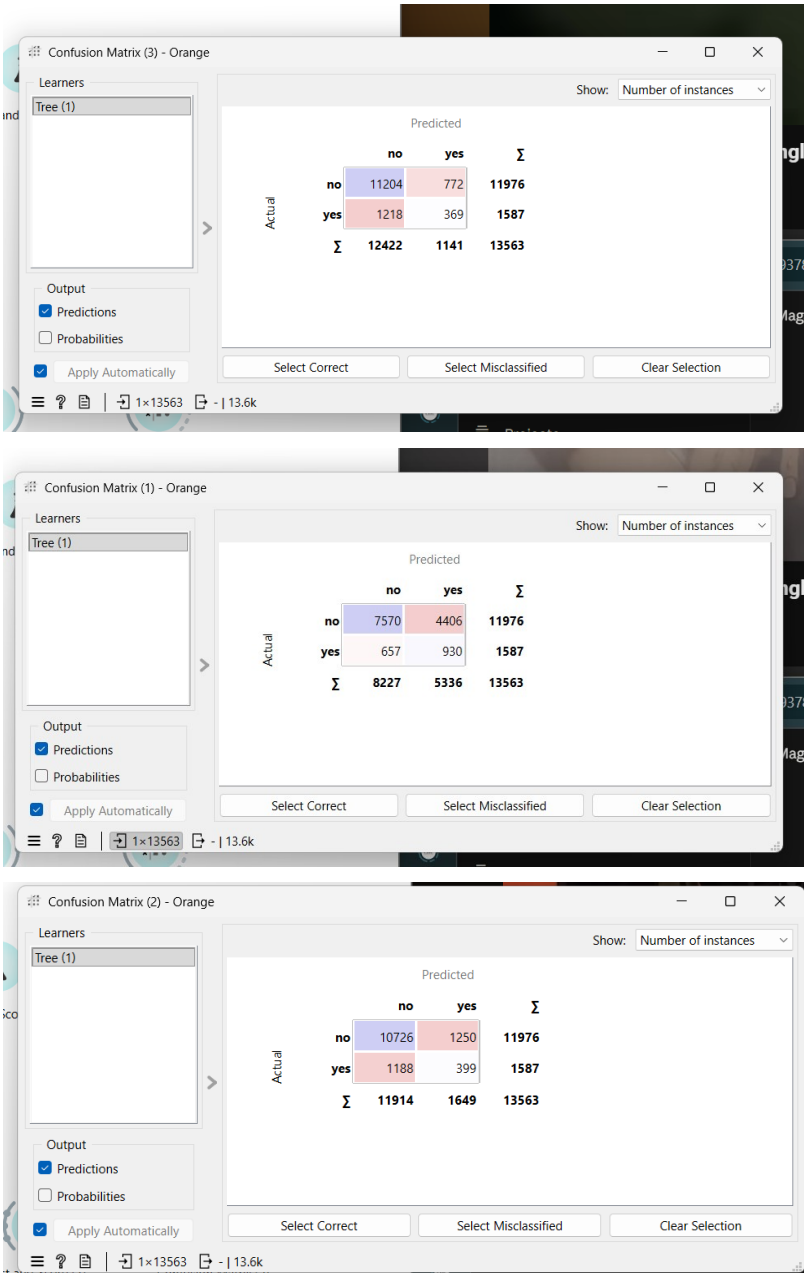
Dari tabel tersebut diperoleh akurasi 89,01% ((38.265 + 1.977) / 45.211), precision 54,40% (1.977 / 3.634), dan recall 37,38% (1.977 / 5.289). Nilai ini sesuai dengan hasil pada Test and Score. Model sangat baik mengenali kelas no (38.265 dari 39.922 atau 95,85%), tetapi 3.312 nasabah yes (62,62%) salah diprediksi sebagai no.

4.3 Eksperimen 2: Hasil Penanganan Data Tidak Seimbang

Hasil ketiga skenario pada data uji yang sama (13.563 *instance*, terdiri atas 1.587 yes dan 11.976 no) disajikan pada kedua tabel dibawah ini. Confusion Matrix tiap skenario ditunjukkan pada kedua gambar dibawah ini.

Skenario	AUC	CA	F1	Prec.	Recall	MCC
A. Tanpa balancing	0,590	0,853	0,271	0,323	0,233	0,195
B. Undersampling acak	0,630	0,627	0,269	0,174	0,586	0,144
C. SMOTE-NC	0,590	0,820	0,247	0,242	0,251	0,145

Skenario	TN	FP	FN	TP
A. Tanpa balancing	11.204	772	1.218	369
B. Undersampling acak	7.570	4.406	657	930
C. SMOTE-NC	10.726	1.250	1.188	399



Perubahan setiap teknik terhadap *baseline* (skenario A) dirangkum pada tabel berikut, dinyatakan dalam poin persentase.

Skenario	Recall	Precision	Accuracy	F1
B. Undersampling acak	+35,3	−14,9	−22,7	−0,2
C. SMOTE-NC	+1,9	−8,1	−3,3	−2,4

Skenario A (baseline). Akurasi tinggi (85,3%), tetapi recall kelas yes hanya 23,3%. Dari 1.587 nasabah yang sebenarnya berlangganan, hanya 369 yang terdeteksi dan 1.218 terlewat. Ini sejalan dengan hasil eksperimen 1.

Skenario B (undersampling acak). Recall naik tajam menjadi 58,6% (+35,3 poin) dan jumlah nasabah yes yang terdeteksi naik dari 369 menjadi 930. Harganya, precision turun menjadi 17,4% dan akurasi menjadi 62,7%, karena salah prediksi yes (FP) naik dari 772 menjadi 4.406, atau sekitar 5,7 kali lipat. F1 hampir tidak berubah (27,1% menjadi 26,9%), sehingga teknik ini terutama menukar precision dengan recall dan bukan memperbaiki kinerja secara keseluruhan. AUC sedikit meningkat (0,590 menjadi 0,630), sedangkan MCC turun (0,195 menjadi 0,144). Teknik ini layak dipilih apabila kerugian melewatkan nasabah potensial dinilai lebih besar daripada biaya menghubungi nasabah yang tidak berminat.

Skenario C (SMOTE-NC). Perbaikannya terbatas: recall hanya naik 1,9 poin menjadi 25,1%, sedangkan precision turun 8,1 poin dan F1 turun menjadi 24,7%. AUC tidak berubah (0,590). Penulis menduga data sintetis tidak menambah informasi baru karena hanya tujuh atribut yang dipakai, dan pohon dengan pengaturan bawaan dapat menyesuaikan diri berlebihan terhadap data sintetis. Dugaan ini belum diuji.

Keterbatasan. Hasil berasal dari satu kali pembagian data, satu nilai seed, dan satu algoritma dengan parameter bawaan. Perbedaan kecil antarskenario, misalnya beberapa poin persentase pada recall skenario C, belum tentu bermakna. Pengulangan dengan beberapa seed atau cross validation diperlukan untuk kesimpulan yang lebih kuat.

4.4 Catatan Penanganan Data Tidak Seimbang di Orange

Penelusuran pustaka menunjukkan bahwa Orange tidak menyediakan widget SMOTE bawaan, dan pada halaman FAQ resminya pengembang menyatakan bahwa terdapat alasan mengapa mereka tidak mengimplementasikannya (Orange Data Mining, n.d.). Terdapat pula add-on komunitas bernama Orange Plus yang memuat widget SMOTE (Papadopoulos, 2020), tetapi add-on tersebut bukan bagian dari distribusi resmi dan tidak diuji pada laporan ini. Eksperimen 2 menunjukkan

bahwa balancing tetap dapat dilakukan di Orange melalui widget Python Script, dengan beberapa catatan praktis berikut.

1. Pustaka imbalanced-learn tidak ikut terpasang pada installer standalone dan harus dipasang manual melalui Command Prompt dengan python.exe milik Orange.
2. Kode balancing harus ditulis sendiri pada widget Python Script, sedangkan di KNIME tersedia node siap pakai.
3. SMOTE biasa tidak cocok untuk dataset dengan atribut kategorikal seperti bank-full.csv, sehingga dipakai SMOTE-NC dengan indeks atribut kategorikal yang ditentukan dari domain data.
4. Balancing harus dibatasi pada data latih. Di Orange hal ini dicapai dengan memisahkan data lewat Data Sampler dan mengevaluasi dengan Test on test data.

4.5 Perbandingan Fitur dan Karakteristik

Perbandingan karakteristik kedua perangkat disajikan pada tabel dibawah ini. Perbandingan ini disusun berdasarkan pengalaman penulis menggunakan keduanya dan dokumentasi resmi, dan beberapa pernyataan bersifat umum.

Aspek	Orange	KNIME
Unit kerja	Widget	Node
Eksekusi	Otomatis, hasil diperbarui saat input atau pengaturan berubah	Manual, node dijalankan (execute) satu per satu atau bersamaan
Visualisasi	Sangat interaktif, data terpilih dapat diteruskan ke widget lain	Ditampilkan pada jendela tampilan node, cenderung lebih statis
Cakupan fitur	Lebih ringkas, berfokus pada data mining dan pembelajaran mesin dasar	Lebih luas, mencakup integrasi basis data, skrip Python dan R, serta pemrosesan data besar
Skala data	Data dimuat di memori, cocok untuk dataset kecil sampai menengah	Umumnya lebih siap untuk data besar dan alur kerja produksi
Kurva belajar	Lebih landai, cocok untuk pemula	Lebih curam, tetapi lebih fleksibel
Penanganan data tidak seimbang	Tidak ada widget SMOTE bawaan; dapat dilakukan lewat Python Script dengan imbalanced-learn (diuji pada laporan ini) dan pustakanya dipasang manual	Tersedia node Equal Size Sampling dan SMOTE
Ekstensi	Add-on melalui menu Options, Add-ons, dan pustaka Python tambahan	Extension dan komponen komunitas melalui KNIME Hub
Format workflow	.ows	.knwf

4.6 Perbandingan Hasil Eksperimen Balancing

Eksperimen balancing pada kedua perangkat memakai dataset yang sama dan dirancang semirip mungkin. Kesamaan dan perbedaan kondisinya dirangkum pada tabel dibawah ini.

Aspek	KNIME	Orange
Dataset	bank-full.csv (45.211 baris)	bank-full.csv (45.211 baris)
Atribut	7 fitur dan target y	7 fitur dan target y
Pembagian data	Table Partitioner 70:30, stratified, seed 42 (uji 13.564)	Data Sampler 70:30, stratified, replicable (uji 13.563)
Algoritma	Decision Tree (parameter bawaan KNIME)	Tree (parameter bawaan Orange)
Skenario B	Equal Size Sampling	Undersampling acak (Python Script)
Skenario C	Category to Number, lalu SMOTE	SMOTE-NC (Python Script)

Hasil kedua perangkat pada kelas yes disajikan pada tabel skenario, yang masing-masing berisi informasi terhadap perubahan terhadap *baseline* masing-masing pada tabel teknik. Angka KNIME diambil dari laporan pekan ketiga.

Skenario	Perangkat	Accuracy	Precision	Recall	F1
A. Tanpa balancing	KNIME	84,4	30,5	26,5	28,4
	Orange	85,3	32,3	23,3	27,1
B. Undersampling	KNIME	59,6	16,8	62,2	26,5
	Orange	62,7	17,4	58,6	26,9
C. SMOTE	KNIME	77,3	12,8	16,2	14,3
	Orange	82,0	24,2	25,1	24,7

Teknik	Perangkat	Recall	Precision	Accuracy	F1
Undersampling	KNIME	+35,7	−13,7	−24,8	−1,9
Undersampling	Orange	+35,3	−14,9	−22,7	−0,2
SMOTE	KNIME	−10,3	−17,7	−7,1	−14,1
SMOTE-NC	Orange	+1,9	−8,1	−3,3	−2,4

Baseline serupa. Tanpa balancing, kedua perangkat menunjukkan pola yang sama: akurasi tinggi (84,4% dan 85,3%) tetapi recall kelas yes rendah (26,5% dan 23,3%).

Undersampling berperilaku hampir sama. Pada kedua perangkat recall naik sekitar 36 poin (+35,7 di KNIME dan +35,3 di Orange), dengan penurunan precision (−13,7 dan −14,9) dan akurasi yang besar, sedangkan F1 nyaris tidak berubah (−1,9 dan −0,2). Kemiripan ini menunjukkan bahwa undersampling acak di Orange lewat Python Script memberikan efek yang setara dengan Equal Size Sampling di KNIME.

SMOTE menunjukkan perbedaan. Pada KNIME, SMOTE menurunkan recall (−10,3 poin) dan F1 (−14,1 poin), sedangkan pada Orange SMOTE-NC menaikkan recall tipis (+1,9 poin) dan menurunkan F1 lebih kecil (−2,4 poin). Salah satu kemungkinan penyebabnya adalah perbedaan penanganan atribut kategorikal: di KNIME atribut kategorikal diubah menjadi angka sebelum SMOTE, sedangkan

SMOTE-NC memperlakukannya sebagai kategori. Penjelasan ini bersifat dugaan dan belum diuji.

Catatan kehati-hatian. Pembagian data, seed, dan parameter bawaan algoritma pada kedua perangkat tidak identik, dan hasilnya berasal dari satu kali pembagian. Oleh karena itu perbandingan lebih tepat dibaca pada pola perubahan daripada pada selisih angka absolut.

4.7 Ringkasan Perbandingan

1. **Orange** unggul untuk eksplorasi cepat dan pembelajaran karena eksekusinya otomatis, visualisasinya interaktif, dan antarmukanya ringan.
2. **KNIME** unggul untuk alur kerja yang lebih kompleks karena cakupan node yang luas, kontrol eksekusi per node, dan tersedianya teknik balancing siap pakai.
3. Untuk dataset tidak seimbang, hasil kedua perangkat serupa pada undersampling, tetapi di Orange balancing memerlukan pemasangan pustaka dan penulisan kode Python, sedangkan di KNIME cukup memakai node yang tersedia.

BAB V KESIMPULAN DAN SARAN

5.1 Kesimpulan

1. Orange Data Mining berhasil dipasang pada Windows menggunakan installer standalone dan dapat langsung digunakan tanpa konfigurasi tambahan.
2. Orange menyediakan enam kategori widget utama (Data, Transform, Visualize, Model, Evaluate, Unsupervised) yang mencakup alur data mining dari pemuatan data hingga evaluasi model.
3. Pada dataset bank-full.csv yang tidak seimbang (no 88,30%, yes 11,70%), Random Forest memberikan hasil terbaik dengan AUC 0,911, F1 0,508, dan recall 0,426 pada kelas yes. Recall seluruh model masih di bawah 43%, sehingga akurasi saja tidak memadai untuk menilai kinerja.
4. Balancing dapat dilakukan di Orange meskipun tidak ada widget SMOTE bawaan, yaitu melalui widget Python Script dengan pustaka imbalanced-learn yang dipasang manual. Pada pembagian data 70:30, undersampling acak menaikkan recall kelas yes dari 23,3% menjadi 58,6% dengan penurunan precision dari 32,3% menjadi 17,4% dan F1 yang hampir tetap, sedangkan SMOTE-NC hanya memberi perbaikan recall yang kecil (25,1%).
5. Pola hasil Orange dan KNIME serupa pada baseline dan undersampling, tetapi berbeda pada SMOTE. Perbedaan penyebabnya belum diuji, dan perbandingan numerik belum sepenuhnya setara karena pembagian data dan parameter bawaan algoritma yang berbeda.
6. Orange lebih ringan dan interaktif, sedangkan KNIME lebih luas dan terkontrol serta menyediakan balancing siap pakai.

5.2 Saran

1. Mengulang eksperimen balancing dengan beberapa nilai seed atau cross validation, dan pada kedua perangkat dengan algoritma dan parameter yang sama, agar perbandingan lebih kuat.

2. Membatasi kedalaman Tree untuk memeriksa dugaan overfitting, dan mencoba algoritma lain (misalnya Random Forest) pada skenario balancing.
3. Menguji SMOTE-NC dengan seluruh atribut, serta melanjutkan eksplorasi Orange ke klasterisasi, asosiasi, regresi, dan add-on.

DAFTAR PUSTAKA

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.

Demšar, J., Curk, T., Erjavec, A., Gorup, Č., Hočevar, T., Milutinović, M., ... Zupan, B. (2013). Orange: Data mining toolbox in Python. *Journal of Machine Learning Research*, 14, 2349–2353.

Lemaître, G., Nogueira, F., & Aridas, C. K. (2017). Imbalanced-learn: A Python toolbox to tackle the curse of imbalanced datasets in machine learning. *Journal of Machine Learning Research*, 18(17), 1–5.

Moro, S., Cortez, P., & Rita, P. (2014). A data-driven approach to predict the success of bank telemarketing. *Decision Support Systems*, 62, 22–31.

Orange Data Mining. (n.d.). *Download Orange*. https://orangedatamining.com/download/

Orange Data Mining. (n.d.). *Frequently asked questions*. https://orangedatamining.com/faq/

Papadopoulos, P. (2020). *Orange Plus: Add-on for Orange3 with custom widgets*. https://github.com/panatronic-git/orange-plus

Python Package Index. (n.d.). *Orange3*. https://pypi.org/project/Orange3/

UCI Machine Learning Repository. (n.d.). *Bank Marketing dataset*. https://archive.ics.uci.edu/dataset/222/bank+marketing